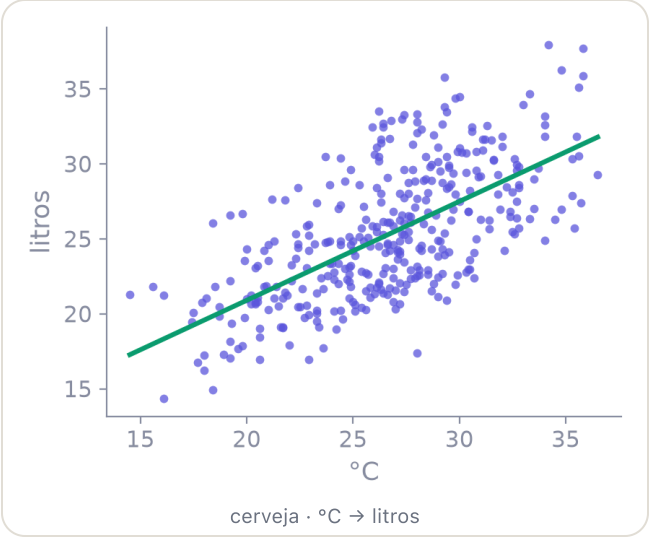
PROGRAMAÇÃO PARA CIÊNCIA DE DADOS · 2026.1

Regressão linear

A melhor reta pelos dados, o que ela aprende
e como saber se o modelo está bom

AULA ML 02 • 08/10 • REGRESSÃO E MÉTRICAS



cerveja · °C → litros

O MODELO MAIS SIMPLES DE ML

O que é regressão linear

REGRESSÃO LINEAR

Você traça a **melhor linha reta** que passa pelos seus dados. Essa linha serve para **prever valores novos**.

Entra

um número que você conhece. Ex.: o tamanho da casa, em m².

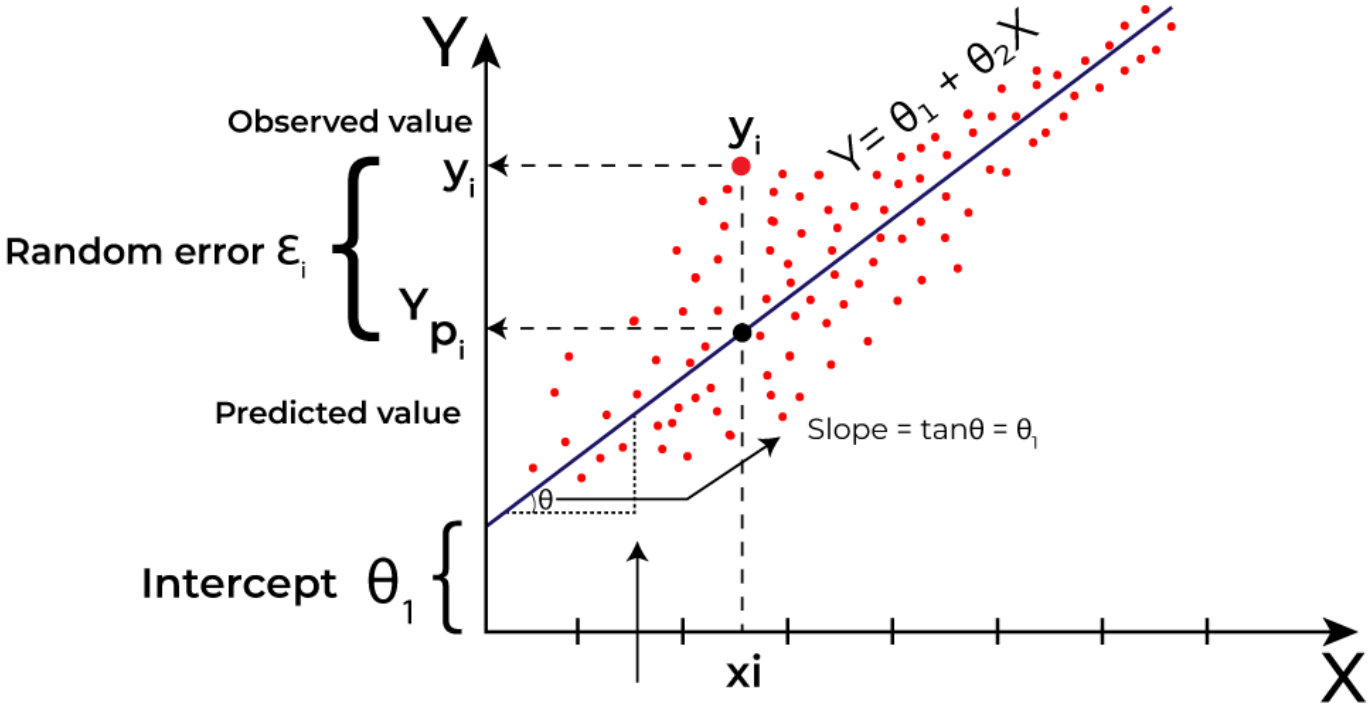
Sai

um número que você quer prever. Ex.: o preço da casa.

Treinar o modelo = achar a reta que fica **o mais perto possível** de todos os pontos ao mesmo tempo.

A RETA INTEIRA CABE EM DOIS NÚMEROS

Inclinação e intercepto



EXEMPLO INVENTADO · TAMANHO → PREÇO

Exemplo: preço de casas

RETA APRENDIDA (EXEMPLO)

preço (mil R$) = **50** + **3** × m²

Inclinação = 3
cada m² a mais adiciona **R$ 3 mil** ao preço.

Intercepto = 50
a altura de partida da reta: R$ 50 mil.

CASA NOVA	CONTA	PREÇO PREVISTO
90 m²	50 + 3 × 90 = 50 + 270	**R$ 320 mil**

Entra um tamanho que o modelo nunca viu, ele aplica a reta e devolve o preço.

POR QUE COMEÇAR POR AQUI

Três pontos importantes

É supervisionado
treina com exemplos que têm **entrada e saída**: casas com tamanho **e** preço já conhecidos.

É interpretável
a inclinação tem significado direto: "cada m² a mais vale R$ 3 mil". Dá para explicar para qualquer pessoa.

É a base de tudo
redes neurais são, no fundo, várias regressões lineares **empilhadas**, com funções não lineares entre elas.

NÃO É OBRIGATÓRIO TER UMA ENTRADA SÓ

E se eu tiver mais colunas?

RESPOSTA CURTA

Pode ter **quantas colunas quiser**: 5, 6, 8... Em vez de uma reta, o modelo vira um **hiperplano**.

1 coluna de entrada
você conhece a temperatura. O consumo é a resposta, no outro eixo. A figura é uma reta.

2 colunas de entrada
temperatura e fim de semana. A resposta vai para o terceiro eixo. A figura é um plano.

3 ou mais
não cabe num desenho. A conta continua a mesma soma.

UM COEFICIENTE PARA CADA COLUNA

A fórmula vira uma soma

PREVISÃO

$$y(x) = \sum_{d=1}^{D} w_d \phi(x_d) + \varepsilon$$

w = pesos (coeficientes) · **ϕ(x)** = as colunas de entrada · **ε** = ruído (o erro que sobra) · **D** = número de colunas

Cinco colunas → cinco coeficientes. Cada um diz quanto aquela coluna **empurra a saída** para cima (+) ou para baixo (–).

O treino é o mesmo de antes: minimizar o erro quadrático médio, agora procurando o melhor **conjunto** de coeficientes.

A MÉTRICA PRINCIPAL

R^2: quanto da variação o modelo explica

R^2 (R AO QUADRADO)

A **fração da variação** da saída que o modelo conseguiu explicar. Vai até 1.

$$R^2 = 1 - \frac{\sum \left(y - \hat{y}\right)^2}{\sum \left(y - \bar{y}\right)^2}$$

y real · **ŷ** previsto · **ȳ** média dos reais

R^2	COMO LER
1,0	acerta tudo (na prática, desconfie)
0,9	já é considerado forte para regressão (depende da área)
0,8	captura 80% do que faz os preços mudarem
0	não explica nada: igual a chutar sempre a média

EXEMPLO INVENTADO · CASAS QUE O MODELO NÃO VIU

Exemplo: 4 casas de teste

Modelo: preço = 50 + 3 × m² (em mil R$). Erro = previsto − real.

CASA	M²	PREVISTO	REAL	ERRO
A	60	230	220	+10
B	80	290	295	−5
C	100	350	365	−15
D	120	410	460	**−50**

A casa D tem um **erro grande** (talvez uma reforma que o modelo não conhece). Vamos usar esta tabela em todas as métricas.

O R² SOZINHO ENGANA

R² ajustado: penaliza coluna inútil

MELHOR QUE O R² PARA COMPARAR MODELOS

$$R^2_{\text{aj}} = 1 - \left(1 - R^2\right)\frac{n-1}{n-p-1}$$

n = número de casos · **p** = número de colunas de entrada

No treino, o R² nunca cai
ao adicionar uma coluna, ele sobe ou fica igual, **mesmo que a coluna seja lixo** (ex.: cor do portão).

O R² ajustado desconta
cada coluna a mais custa um pouco. Se ela não ajuda de verdade, o ajustado **cai**.

EXEMPLO (50 CASAS)	R²	R² AJUSTADO
5 colunas úteis	0,80	0,78
+ 5 colunas lixo	0,81 ↑	0,76 ↓

Atenção: "nunca cai" vale **só no treino**. No teste, o R² pode cair e até ficar **negativo** (pior que chutar a média).

AS QUATRO CASAS DO SLIDE ANTERIOR

MAE: em média, errou quanto

O modelo errou **10**, **5**, **15** e **50** mil reais. O sinal não entra: 10 a mais ou 10 a menos é o mesmo erro.

SOME E DIVIDA POR 4

(10 + 5 + 15 + 50) / 4 = **20**

$$\text{MAE} = \frac{1}{n}\sum \left| y - \hat{y} \right|$$

MAE = 20. Em média, o modelo errou **R$ 20 mil**. Menor é melhor.

ANTES DOS CADERNOS 02 E 03

MLflow

Biblioteca que guarda cada treino, para comparar depois. Site: **https://mlflow.org**

Experimento
a pasta das tentativas. Nesta aula, o nome é **cerveja**.

Run
uma tentativa. Tem nome, o que entrou, os números e os arquivos.

UMA VEZ, NO COMEÇO DO CADERNO

Inicializar

```
import os
os.environ["MLFLOW_ALLOW_FILE_STORE"] = "true"

import mlflow
mlflow.set_tracking_uri("mlruns")
mlflow.set_experiment("cerveja")
```

MLFLOW_ALLOW_FILE_STORE libera a pasta **mlruns**. **set_tracking_uri** diz onde gravar. **set_experiment** abre o experimento, ou cria se não existir.

DENTRO DO TREINO

Gravar a run

```python
with mlflow.start_run(run_name="temperatura"):
    mlflow.log_param("entradas", "Temperatura Maxima (C)")
    mlflow.log_metrics({"mae": mae, "r2": r2})
    mlflow.log_artifact("reta.png")
    mlflow.log_input(mlflow.data.from_pandas(dataset, name="cerveja"), context="training")
    mlflow.sklearn.log_model(modelo, name="modelo")
```

MÉTODO	O QUE GRAVA
start_run	abre a run, com um nome
log_param	um texto: quais colunas entraram
log_metrics	números: MAE e R^2
log_artifact	um arquivo: a figura da reta
log_input	o arquivo de dados. Enche a coluna Dataset
sklearn.log_model	a reta treinada. Enche a coluna Models

A TABELA DAS RUNS

Abrir

```
MLFLOW_ALLOW_FILE_STORE=true mlflow ui --backend-store-uri mlruns
```

Abre **http://127.0.0.1:5000**. Lá está o experimento **cerveja**, uma linha por run.

No Python, **mlflow.search_runs** lê essa mesma tabela. É o que o caderno 03 usa para desenhar o gráfico.