Algoritmos de classificação

Apostila para ler no lugar da aula: quatro jeitos de responder “o cliente sai ou fica?”, no mesmo problema, comparados no mesmo teste.

Como ler: siga na ordem. Cada algoritmo tem a ideia, a fórmula e um exemplo com um cliente de verdade. Todos os números saíram do caderno `aula-ml-3.ipynb`, que você pode rodar no fim (seção 7).

1 Classificar: escolher uma categoria

Até aqui vimos dois tipos de pergunta. Na **aula 1**, com os pinguins, a resposta era **uma opção de uma lista**: Adelie, Chinstrap ou Gentoo. Isso é **classificação**. Na **aula 2**, com a cerveja, a resposta era **um número**: quantos litros. Isso é **regressão**. Hoje voltamos à classificação, com uma pergunta de sim ou não.

PERGUNTA	RESPOSTA	TIPO
Qual é a espécie do pinguim? (aula 1)	1 de 3 opções	classificação
Quantos litros de cerveja amanhã? (aula 2)	um número	regressão
Este cliente vai cancelar? (hoje)	**sim ou não**	**classificação**

Na aula 1 usamos **um** algoritmo (a regressão logística). Hoje veremos **quatro**, cada um decidindo de um jeito, e comparamos qual acerta mais.

O caso: Telco Customer Churn

Um arquivo público com clientes de uma empresa de telefonia e internet, uma linha por cliente. O arquivo tem 7.043 linhas. Em 11 delas o total pago está vazio; essas saem, e ficam **7.032 clientes**. *Churn* é a palavra em inglês para “o cliente cancelou”.

Fonte: Kaggle, https://www.kaggle.com/datasets/blastchar/telco-customer-churn (dados de exemplo da IBM). Baixe o CSV e salve como `dados/WA_Fn-UseC_-Telco-Customer-Churn.csv`, na pasta da aula.

> *Pergunta de negócio: dado um cliente com tal tempo de casa, tal conta e tal contrato, qual a probabilidade de ele cancelar?*

O arquivo tem 21 colunas. Usamos só 4 de entrada, mais a resposta:

COLUNA	O QUE É	PAPEL
tenure	meses de casa (há quanto tempo é cliente)	entrada
MonthlyCharges	conta mensal, em US$	entrada
TotalCharges	total já pago, em US$	entrada
Contract	tipo de contrato: mensal, 1 ano ou 2 anos	entrada
Churn	**cancelou? sim ou não · 26,6% saem**	**coluna alvo**

> APRENDIZADO SUPERVISIONADO
> A coluna da resposta (Churn) já existe no arquivo. O modelo aprende com clientes que já sabemos se saíram ou ficaram, e depois responde para clientes novos.

Treino e teste

Separamos os clientes em dois grupos: **75% para treino** (5.274 clientes) e **25% para teste** (1.758). Os dois grupos têm a mesma porcentagem de quem sai. O modelo aprende **só com o treino**; depois medimos quanto ele acerta no teste, em clientes que ele nunca viu. É como estudar com uma lista de exercícios e fazer a prova com questões novas.

Preparo (igual para os quatro): as três colunas numéricas vão para **a mesma escala** (senão o total pago, na casa dos milhares, pesa mais que os meses, na casa das dezenas), e o contrato, que é texto, vira três colunas de 0 e 1.

ANTES DE COMEÇAR: O CLIENTE QUE VAMOS ACOMPANHAR

Seguimos um mesmo cliente do teste, o **cliente 157**: **2 meses** de casa, conta de **US$ 95,65** por mês, **US$ 167,30** pagos no total, **contrato mensal**. Os modelos não sabem a resposta, mas nós sabemos: na vida real, **ele saiu**.

2 Regressão logística

Algoritmo 1 de 4 · o mesmo da aula 1

A IDEIA

Dá uma **nota** para o cliente somando pistas: cada coluna empurra para "sai" ou para "fica", com uma força (o peso) que o modelo aprendeu no treino. Depois transforma essa nota numa **probabilidade** entre 0 e 1.

A fórmula: duas contas

1 · A NOTA (SCORE)

$$z = w_1 x_1 + w_2 x_2 + \ \ldots \ + w_n x_n + b$$

2 · A PROBABILIDADE (SIGMOIDE)

$$p = \frac{1}{1 + e^{-z}}$$

x = valor de cada coluna do cliente · **w** = peso aprendido para cada coluna · **b** = ponto de partida · **z** = a nota · **e** ≈ 2,718 · **p** = probabilidade de sair. Se **z** é negativo, **p** fica abaixo de 0,5; se **z** = 0, **p** = 0,5; se **z** é positivo, **p** fica acima de 0,5. A regra final: **p ≥ 0,5** → **"sai"**.

Os pesos que o modelo aprendeu

Peso positivo empurra para "sai", negativo empurra para "fica". Como as colunas foram colocadas na mesma escala, dá para comparar os pesos entre si.

COLUNA	PESO	LEITURA
meses de casa (tenure)	−1,23	mais meses → mais chance de ficar (o mais forte)
conta do mês	+0,73	conta alta → mais chance de sair
total já pago	+0,39	empurra para sair (peso menor)
contrato mensal	+0,55	empurra para sair
contrato de 1 ano	−0,60	empurra para ficar
contrato de 2 anos	−1,30	empurra forte para ficar

Cliente 157, passo a passo

1. O cliente: 2 meses, US$ 95,65/mês, contrato mensal. **Poucos meses**, **conta alta** e **contrato mensal**: todas as pistas fortes apontam para "sai".
2. Somando peso × coluna (mais o ponto de partida), a nota dá **z = 0,95**. Positiva.
3. Na sigmoide: $p = \frac{1}{1 + e^{-0{,}95}} = 0{,}72$.
4. 0,72 ≥ 0,5 → **"sai"**. Na vida real ele saiu: **acertou**.

QUANDO USAR

Quando você quer **explicar o porquê**: cada coluna tem um peso que dá para ler. É um bom primeiro modelo para testar.

CUIDADO

Cada coluna empurra **sempre para o mesmo lado**. Ela não monta regras do tipo "se isto *e* aquilo". Precisa das colunas na mesma escala.

3 KNN: os k vizinhos mais próximos

Algoritmo 2 de 4 · KNN = *k nearest neighbors*

A IDEIA

Para um cliente novo, procura no treino os clientes **mais parecidos** com ele e copia a resposta da **maioria**. Aqui usamos os 5 mais parecidos (k = 5). Não há pesos para aprender: "treinar" é só guardar o treino.

A fórmula: parecido = perto

1 · A DISTÂNCIA ENTRE DOIS CLIENTES (EUCLIDIANA)

$$d(x, y) = \sqrt{\sum_{i=1}^{n} (x_i - y_i)^2}$$

2 · O VOTO

resposta = a classe **mais comum** entre os **k** vizinhos de menor **d**

x = cliente novo · **y** = um cliente do treino · **i** = cada coluna · **n** = número de colunas · **d** = distância (0 = idênticos) · **k** = quantos vizinhos votam. Em palavras: para cada coluna, faz a diferença entre os dois clientes, eleva ao quadrado, soma tudo e tira a raiz. É a régua da escola, só que com várias colunas.

Cliente 157, passo a passo

O KNN mediu a distância do cliente 157 até os 5.274 clientes do treino e pegou os 5 mais perto (distâncias medidas com as colunas já na mesma escala):

VIZINHO	DISTÂNCIA D	MESES	CONTA DO MÊS	TOTAL PAGO	CONTRATO	SAIU?
1	0,008	2	US$ 95,50	US$ 181,65	mensal	não
2	**0,012**	**2**	**US$ 96,00**	**US$ 174,80**	**mensal**	**sim**
3	**0,021**	**2**	**US$ 95,15**	**US$ 196,90**	**mensal**	**sim**
4	**0,024**	**2**	**US$ 94,95**	**US$ 178,10**	**mensal**	**sim**
5	**0,048**	**2**	**US$ 94,20**	**US$ 167,50**	**mensal**	**sim**

1. Os vizinhos são quase iguais a ele: 2 meses, conta perto de US$ 95, contrato mensal.
2. Voto: 4 de 5 saíram → 4 ÷ 5 = **0,80**.
3. A maioria saiu → **"sai"**. Na vida real ele saiu: **acertou**.

QUANDO USAR

Quando clientes parecidos tendem a fazer a mesma coisa. É a ideia mais fácil de explicar: "quem era igual a você fez isto".

CUIDADO

Compara com **todo o treino** a cada cliente novo (fica lento com muitos dados). E depende da escala: sem ela, o total pago (milhares) abafa os meses (dezenas) no cálculo da distância.

4 Naive Bayes

Algoritmo 3 de 4 · no caderno, `GaussianNB`

A IDEIA

Pergunta, coluna por coluna: este valor é mais comum entre **quem sai** ou entre **quem fica**? Depois junta todas essas pistas com a proporção de quem sai no treino.

A fórmula: juntar as pistas multiplicando

CHANCE DE SAIR, DADO O CLIENTE

$$P(\text{sai} \mid x) \propto P(\text{sai}) \cdot \prod_{i=1}^{n} P(x_i \mid \text{sai})$$

SÍMBOLO	EM PALAVRAS
$P(\text{sai} \mid x)$	chance de sair, olhando o cliente **x** (é o que queremos)
$P(\text{sai})$	proporção de quem sai no treino, antes de olhar o cliente: **0,266**
$P(x_i \mid \text{sai})$	quão comum é o valor da coluna **i** entre quem sai
$\prod$	multiplica as **n** colunas, uma pista de cada
$\propto$	“proporcional a”: faz a mesma conta para “fica” e divide para as duas somarem 1

Cliente 157, passo a passo

O modelo guarda o perfil médio de quem fica e de quem sai no treino. Compare com o cliente 157:

MÉDIA NO TREINO	MESES DE CASA	CONTA DO MÊS	TOTAL JÁ PAGO
quem **fica**	37,6	US$ 61,60	US$ 2.556,85
quem **sai**	17,8	US$ 74,12	US$ 1.508,23
cliente 157	**2**	**US$ 95,65**	**US$ 167,30**

1. Começa com **P(sai) = 0,266**: no treino, 26,6% saem.
2. Nas três colunas numéricas, o cliente fica **mais perto do perfil de quem sai**. Cada pista puxa a conta para o lado de “sai”.
3. Juntando tudo e dividindo para somar 1: **P(sai | cliente) = 0,98 → “sai”**. Na vida real ele saiu: **acertou**, mas com 98% de certeza, o que é demais (veja o cuidado abaixo).

QUANDO USAR

Quando você precisa de algo **muito rápido**, com pouco dado ou com muitas colunas. É clássico em filtro de spam.

CUIDADO

“Naive” = **ingênuo**: trata cada coluna como uma pista separada. Mas meses e total pago andam juntos (quem tem poucos meses pagou pouco). A mesma pista conta duas vezes, e o modelo fica **confiante demais**.

5 Árvore de decisão

Algoritmo 4 de 4 · aqui com no máximo 4 perguntas (`max_depth=4`)

A IDEIA

Faz **perguntas de sim ou não**, uma depois da outra, como um fluxograma. Cada resposta leva a um grupo menor de clientes, até chegar numa **folha**. A resposta é o que a maioria daquela folha fez.

A fórmula: como a árvore escolhe a pergunta (impureza de Gini)

QUÃO MISTURADO ESTÁ UM GRUPO

$$G = 1 - \sum_{k} p_k^2$$

k = cada classe (sai, fica) · $\mathbf{p_k}$ = fração do grupo em cada classe · **G = 0**: grupo puro (todos saem ou todos ficam) · quanto mais misturado, maior (no máximo 0,5 com duas classes).

Exemplo com o treino inteiro, onde 26,6% saem e 73,4% ficam:

$$G = 1 - (0{,}266^2 + 0{,}734^2) = 0{,}39$$

A árvore testa várias perguntas e fica com a que **mais baixa o Gini** (a média dos grupos que sobram, pesada pelo tamanho de cada grupo). A primeira escolhida foi “contrato mensal?”:

CLIENTES DO TREINO	QUANTOS	GINI
todos, antes de perguntar	5.274	0,39
contrato mensal? **sim**	2.920	0,49
contrato mensal? **não**	2.354	0,12
média depois da pergunta		**0,325**

Conta da média: (2.920 × 0,49 + 2.354 × 0,12) ÷ 5.274 ≈ 0,325. Caiu de 0,39 para 0,325: a pergunta separou bem quem fica (o grupo “não” ficou quase puro).

Cliente 157, passo a passo: as 4 perguntas que ele respondeu

1. Contrato mensal? **sim**
2. Conta do mês acima de US$ 68,72? **sim** (US$ 95,65)
3. Até 15,5 meses de casa? **sim** (2 meses)
4. Total pago acima de US$ 118,10? **sim** (US$ 167,30)

Ele cai numa folha com **630 clientes do treino**, dos quais **61% saíram** → probabilidade **0,61** → **“sai”**. Na vida real ele saiu: **acertou**, com menos certeza que os outros: essa folha ainda é bem misturada (Gini 0,475).

QUANDO USAR

Quando você quer **regras que dá para ler e desenhar**: “contrato mensal e conta alta → risco”. Não precisa de escala.

CUIDADO

Com muitas perguntas, ela **decora** o treino e erra clientes novos. Por isso limitamos a 4 perguntas.

PRÓXIMA AULA

Na **aula 4 (22/10)**: árvores e florestas (muitas árvores votando juntas).

6 A comparação: qual se sai melhor?

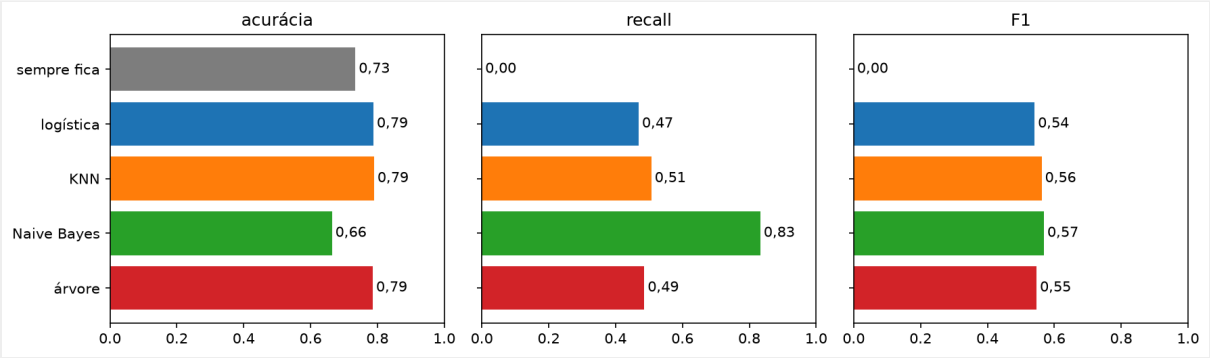
Os quatro treinaram nos **mesmos 5.274** clientes e foram medidos nos **mesmos 1.758** do teste. Para ter uma régua, comparamos também com um "modelo" que nem olha os dados: o chute **"sempre fica"**. Um algoritmo precisa ganhar dele para valer a pena.

As quatro medidas, em palavras

- **Acurácia**: de todos os clientes do teste, quantos % o modelo acertou.
- **Precisão**: dos clientes que o modelo disse "sai", quantos % saíram de verdade. Precisão baixa = muito alarme falso.
- **Recall**: dos clientes que saíram de verdade, quantos % o modelo pegou. Recall baixo = muito cliente perdido sem aviso.
- **F1**: uma nota só que junta precisão e recall. Só é alta se as duas forem boas.

MODELO	ACURÁCIA	PRECISÃO	RECALL	F1
sempre fica (o chute)	0,734	0,000	0,000	0,000
regressão logística	0,788	**0,638**	0,469	0,541
KNN (k = 5)	**0,790**	0,629	0,507	0,562
Naive Bayes	0,664	0,432	**0,833**	**0,569**
árvore (4 perguntas)	0,786	0,625	0,486	0,547

Resultados no teste (1.758 clientes). Em destaque, o melhor de cada coluna.



O mesmo resultado em barras: acurácia, recall e F1, um painel por medida. Leia cada painel separado: barra maior = melhor naquela medida.

Como ler

- O chute "sempre fica" acerta **73,4%** sem fazer nada, porque a maioria fica. Mas não pega **ninguém** que sai (recall 0). Acurácia sozinha engana.
- Logística, KNN e árvore ficam perto de **0,79** de acurácia e pegam cerca de **metade** de quem sai (recall de 0,47 a 0,51).
- O Naive Bayes tem a **menor acurácia** (0,664), mas pega **83%** de quem sai (recall 0,833) e tem o maior F1 (0,569). Em troca, dá mais alarmes à toa (precisão 0,432).
- O cliente 157 foi acertado pelos quatro, com certezas diferentes: logística 0,72 · KNN 0,80 · Naive Bayes 0,98 · árvore 0,61.

> **QUAL ESCOLHER?**
> Depende do **erro que dói mais**. Se perder um cliente sem aviso custa caro → **Naive Bayes** (pega mais quem sai). Se ligar para o cliente à toa custa caro → **logística** (maior precisão, 0,638) ou **KNN**. Não existe "o melhor" sem dizer qual erro importa.

7 Como rodar o caderno e o MLflow

1. Abra o caderno `aula-ml-3.ipynb` na pasta da aula, no mesmo ambiente da aula 2 (pandas, scikit-learn, matplotlib e mlflow). O arquivo de dados fica em `dados/WA_Fn-UseC_-Telco-Customer-Churn.csv`.
2. Rode as células **de cima para baixo** (Run All). O caderno carrega e limpa os dados, separa treino e teste, treina o chute "sempre fica" e os 4 algoritmos com a mesma função, monta a tabela e o gráfico da seção 6, e no fim mostra o cliente 157 em cada modelo (os números das seções 2 a 5).
3. Cada modelo treinado vira uma **run** no MLflow, no experimento **classificadores** (5 runs: sempre-fica, logistica, knn, naive-bayes, arvore), com as 4 medidas gravadas.
4. Para ver as runs, abra um terminal na pasta da aula e rode:

   ```
   MLFLOW_ALLOW_FILE_STORE=true mlflow ui --backend-store-uri mlruns
   ```

   Depois abra `http://127.0.0.1:5000` no navegador, entre em **classificadores**, marque as 5 runs e clique em **Compare**.

Experimente: troque `n_neighbors=5` por outro número no KNN, ou `max_depth=4` na árvore, rode de novo e veja a nova run no MLflow.

8 Resumo

ALGORITMO	IDEIA EM UMA LINHA	CLIENTE 157	BOM PARA	CUIDADO
Regressão logística	soma peso × coluna → probabilidade	0,72	explicar o porquê	cada coluna empurra sempre para o mesmo lado
KNN	segue a maioria dos 5 clientes mais parecidos	0,80	ideia simples, "quem era igual a você"	lento; precisa de escala
Naive Bayes	junta pistas: cada coluna, comparada com quem sai e com quem fica	0,98	rápido; pegou mais quem sai	confiante demais
Árvore de decisão	perguntas de sim ou não até uma folha	0,61	regras que dá para ler	decora o treino se crescer demais

- **Classificação** responde com uma categoria (sai ou fica); **regressão**, com um número.
- Treine num grupo, meça em outro (teste) que o modelo nunca viu.
- Compare sempre com um chute simples: aqui, "sempre fica" já acerta 73,4%.
- Olhe mais que a acurácia: precisão e recall mostram **que tipo de erro** o modelo comete.
- O melhor modelo depende do erro que custa mais para o negócio.

Na aula 4 (22/10): árvores e florestas.