PROGRAMAÇÃO PARA CIÊNCIA DE DADOS · 2026.1 · AULA ML 04 · 22/10

Árvores, florestas e a comparação

Apostila de acompanhamento: prever o preço de diamantes quando a relação deixa de ser uma reta e as categorias se cruzam.

Como ler: siga na ordem. Para cada algoritmo você verá a ideia intuitiva, a fórmula matemática, o código conceitual e o rastreamento passo a passo do **Diamante 157 do teste**. Todos os números vêm do caderno `aula-ml-4.ipynb`.

1 O problema: quando a reta quebra

Na **aula 2**, previmos o custo de um plano de saúde usando **regressão linear**: a resposta era um número contínuo e cada variável somava um valor proporcional ao resultado. Hoje o objetivo continua sendo prever uma grandeza contínua em dólares (o preço de um diamante), mas o comportamento da realidade é completamente diferente:

- **Curvatura não-linear:** o preço não cresce a passos iguais conforme o peso (quilate) sobe. De 0,5 ct para 1,0 ct o preço dobra; de 1,0 ct para 2,0 ct o preço quadruplica ou dispara.
- **Cruzamento de variáveis (interação):** um quilate adicional em uma pedra com corte *Ideal* vale muito mais no mercado do que em uma pedra com corte *Fair*. Uma reta tradicional não enxerga essa interação sem termos manuais de multiplicação cruzada.

> **A REGRA PEDAGÓGICA**
> O alvo ser um número contínuo não decide o algoritmo. Quem decide o algoritmo é a **forma da relação** entre as variáveis e o alvo.

O Dataset: Diamonds (Kaggle)

Utilizamos a base internacional com **53.920 diamantes** (após descartar 20 linhas que apresentavam `x`, `y` ou `z` iguais a zero por falha de registro dos instrumentos). Os dados são divididos em **75% para treino (40.440 pedras)** e **25% para teste (13.480 pedras)** com `random_state=0`.

COLUNA	O QUE REPRESENTA	TIPO	VALORES / ESCALA
carat	Peso físico da gema em quilates (1 ct = 0,2 gramas)	Numérica	0,20 a 5,01 ct
cut	Qualidade do corte e lapidação óptica	Categórica	Fair, Good, Very Good, Premium, Ideal
color	Cor da gema (da ausência à tonalidade amarelada)	Categórica	D (melhor, incolor) a J (mais amarelado)
clarity	Pureza óptica e ausência de inclusões microscópicas	Categórica	IF (pura), VVS1, VVS2, VS1, VS2, SI1, SI2, I1
x, y, z	Comprimento, largura e profundidade em milímetros	Numéricas	Dimensões tridimensionais (mm)
depth, table	Percentual de profundidade total e largura da mesa	Numéricas	Proporções geométricas percentuais
price	**Preço final de venda no atacado internacional**	**Alvo (y)**	**US$ 326 a US$ 18.823**

2 Regressão Linear (A Reta de Referência)

É o nosso *baseline* obrigatório. Ajusta um hiperplano que busca minimizar a soma dos quadrados dos erros (Mínimos Quadrados Ordinários):

EQUAÇÃO DA REGRESSÃO LINEAR

$$\hat{y} = w_1 x_1 + w_2 x_2 + \ \ldots \ + w_n x_n + b$$

VANTAGENS

Fácil de explicar em relatórios e auditorias. Cada peso `w` tem interpretação direta em unidades de preço.

LIMITAÇÕES

Não modela curvaturas nem interações. Assume que cada feature atua de forma independente e linear.

DIAMANTE 157 NA RETA

Pedra de **2,01 quilates, corte Ideal, cor G, clareza SI2**. Preço real no mercado: **US$ 18.259**.
A reta calcula a soma ponderada dos atributos padronizados e prevê **US$ 14.081**. Ela comete um **erro brutal de –US$ 4.178** porque sua inclinação constante é incapaz de acompanhar o salto exponencial das pedras acima de 2 quilates. No teste geral, a reta fecha com **RMSE de US$ 1.142**.

3 Árvore de Decisão: Perguntas e Folhas

Em vez de somar termos contínuos, a árvore particiona o espaço de dados através de sucessivas perguntas de *sim* ou *não*. Para cada divisão, ela busca o atributo e o ponto de corte que provocam a maior **redução de variância residual (MSE)**:

CRITÉRIO DE DIVISÃO NA REGRESSÃO (MSE)

$$MSE = \frac{1}{N}\sum_{i=1}^{N}(y_i - \bar{y})^2, \qquad \text{Ganho} = MSE_{\text{pai}} - \left(\frac{N_E}{N}MSE_E + \frac{N_D}{N}MSE_D\right)$$

A primeira pergunta formulada na raiz foi: **quilate ≤ 1,0?** Ao chegar na folha, a predição é simplesmente a **média aritmética dos diamantes de treino** que caíram naquele nó.

DIAMANTE 157 NA ÁRVORE RASA (PROFUNDIDADE 3)

1. **Nó 0 (Raiz):** Quilate ≤ 1,0? *Não* (tem 2,01 ct) → vai para o ramo direito.
2. **Nó 8:** Largura `y` ≤ 6,73 mm? *Não* (tem 8,10 mm) → vai para a direita.
3. **Nó 12:** Largura `y` ≤ 7,44 mm? *Não* → cai na **folha 14**.

A folha 14 reúne 1.560 pedras grandes do treino. O preço médio é **US$ 14.898** (erro de –US$ 3.361). A árvore rasa ainda é grosseira (RMSE teste de 1.430, pior que a reta).

O Perigo do Overfitting: A Árvore Funda

Se removermos o teto de profundidade (`max_depth=None`), a árvore cresce até ter folhas com apenas 1 ou 2 diamantes. O resultado é dramático:

- **No Treino:** RMSE cai para **US$ 9** (ela decorou os dados de treino!).
- **No Teste:** RMSE fica em **US$ 821**. Uma perda de generalização de quase 90 vezes.

4 Random Forest: O Comitê de Árvores

Uma árvore sozinha tem alta variância e sofre de instabilidade. A **Floresta Aleatória (Random Forest)** resolve isso através do princípio do *Bagging* (Bootstrap Aggregating) combinado com subamostragem aleatória de variáveis:

1. Gera **80 réplicas do treino** por amostragem aleatória com reposição (bootstrap).
2. Treina uma árvore em cada réplica. Em cada divisão de cada nó, apenas um subconjunto aleatório de features é considerado.
3. A previsão final para qualquer diamante novo é a **média aritmética simples** das 80 árvores:

PREVISÃO POR COMITÊ (ENSEMBLE)

$$\hat{y} = \frac{1}{B} \sum_{b=1}^{B} T_b(x)$$

DIAMANTE 157 NA FLORESTA (80 ÁRVORES)

Cada árvore votou de forma independente. As árvores mais cautelosas previram cerca de US$ 10.972; as mais generosas chegaram a US$ 18.168. A média das 80 estimativas convergiu para **US$ 16.131** (reduzindo pela metade o erro das árvores individuais).
No teste geral, a Floresta foi a **campeã absoluta com RMSE de US$ 624** e MAE de US$ 302.

5 Gradient Boosting: Aprendendo com o Erro

Diferente da floresta, onde as árvores operam em paralelo e de forma independente, o **Gradient Boosting** constrói árvores **em sequência**. Cada nova árvore é treinada para prever o **resíduo (o erro)** cometido pela soma das árvores anteriores:

ATUALIZAÇÃO SEQUENCIAL COM TAXA DE APRENDIZADO

$$F_0(x) = \bar{y}, \qquad F_m(x) = F_{m-1}(x) + \nu \cdot h_m(x)$$

Onde $h_m(x)$ é uma árvore rasa ajustada sobre os erros $r_i = y_i - F_{m-1}(x_i)$ e ν é a taxa de encolhimento (*learning rate*). No Diamante 157, o modelo começou na média de US$ 3.933 e, após 80 correções, atingiu **US$ 15.461**. No teste geral, atingiu **RMSE de US$ 891**.

6 KNN Regressor: A Média dos Vizinhos

O KNN (*k-Nearest Neighbors*) opera por similaridade geométrica pura. Ele não constrói fórmulas nem divide nós: calcula a distância euclidiana entre o diamante novo e cada um dos 40.440 diamantes do treino, selecionando os **k = 15 mais próximos**:

DISTÂNCIA EUCLIDIANA E MÉDIA LOCAL

$$d(x, y) = \sqrt{\sum_{i=1}^{n} (x_i - y_i)^2}, \qquad \hat{y} = \frac{1}{k} \sum_{j \in V_k} y_j$$

DIAMANTE 157 NO KNN

O KNN encontrou pedras quase idênticas no treino (todas com corte Ideal, cor G, clareza SI2 e peso entre 2,00 ct e 2,05 ct). A média dos 15 vizinhos foi de **US$ 15.277**. No teste, o KNN atingiu **RMSE de US$ 896**. Porém, seu custo computacional de predição é altíssimo em relação aos modelos de árvores.

7 A Comparação Geral no MLflow

Todos os modelos foram avaliados exatamente nas **mesmas 13.480 pedras de teste**. Os resultados obtidos foram registrados no MLflow (experimento `aula-ml-4-diamonds`):

MODELO	PARÂMETROS PRINCIPAIS	RMSE TESTE	MAE TESTE	RMSE TREINO	DIAGNÓSTICO
Árvore rasa	`max_depth=3`	1.430	812	1.411	Underfitting (perde da reta)
Regressão linear	Padrão (sem teto)	1.142	738	1.122	Baseline de referência linear
KNN	`n_neighbors=15`	896	450	822	Pesado para produção
Gradient Boosting	`n_estimators=80, depth=3`	891	461	872	Competitivo e compacto
Árvore funda	`max_depth=None`	821	384	**9**	Overfitting extremo
Random Forest	**`n_estimators=80, depth=16`**	**624**	**302**	**367**	**Campeã (menor erro geral)**

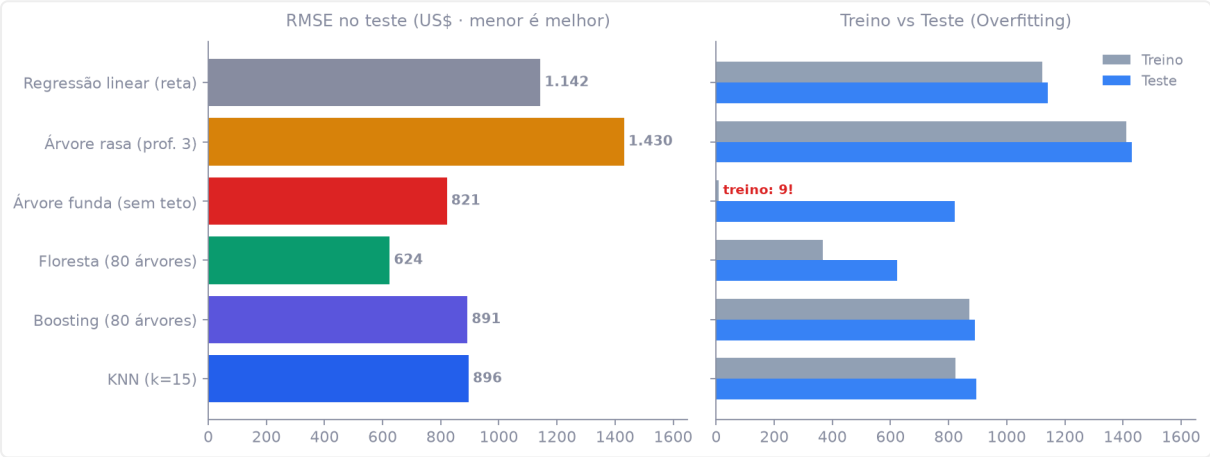


Figura 1: Comparativo de erro no teste (esquerda) e o abismo de overfitting da árvore funda no treino (direita).

Importância por Permutação: O Teste da Verdade

A métrica nativa da árvore (`feature_importances_`) infla o peso de colunas numéricas contínuas com muitas quebras possíveis. A **importância por permutação** é muito mais honesta: ela embaralha aleatoriamente os valores de uma coluna no conjunto de teste e afere quanto o RMSE piora.

- **Quilate (carat):** embaralhar essa coluna piora o RMSE em estarrecedores **+US$ 3.033**! É a coluna decisiva.
- **Dimensão y e clareza:** causam piora de **+US$ 1.956** e **+US$ 1.041** respectivamente.
- **Corte e profundidade:** causam impacto residual menor que US$ 35 quando peso e pureza já são conhecidos.

8 Como Rodar o Caderno e o MLflow

Para reproduzir todas as figuras, runs e tabelas no seu computador:

```
# 1. Ativar o ambiente e executar o script de geração das saídas
python saidas.py

# 2. Iniciar o servidor visual do MLflow para auditar os experimentos
MLFLOW_ALLOW_FILE_STORE=true mlflow ui --backend-store-uri mlruns
```

Abra o navegador em `http://127.0.0.1:5000` . Você verá as 6 runs registradas no experimento `aula-ml-4-diamonds` com suas respectivas métricas e parâmetros.

RESUMO FINAL DA AULA

- Quando o objetivo for **minimizar o erro de previsão** em problemas tabulares com curvas e interações cruzadas: use **Random Forest** (ou Gradient Boosting).
- Quando o objetivo for **justificar e publicar os pesos individuais de cada fator** com total transparência: use a **Regressão linear**, estando consciente do erro que deixa na mesa.