PROGRAMAÇÃO PARA CIÊNCIA DE DADOS · 2026.1

Datasets

De onde vem o dado, o que há dentro dele — e o trabalho que responde pelas duas notas do semestre

AULA 02 • ~3H20 • KAGGLE · TITANIC · NOTEBOOK AO VIVO

ABERTURA

O caminho de hoje

01 **De onde vem o dado**
onde os datasets vivem — e como se avalia um antes de baixar

02 **Mãos na massa**
no notebook, juntos: Titanic, do arquivo bruto a cinco achados

03 **O trabalho**
o projeto final, em detalhe — duas entregas, duas notas

Saia daqui com um **dataset escolhido** e três perguntas rascunhadas. É a tarefa da semana.

01

De onde vem o dado

Onde os datasets vivem · Kaggle por dentro · como avaliar · licença e LGPD — e **só então** baixar

BLOCO 1 · RETOMANDO O MAPA

Onde estamos

Pergunta 1
o que queremos saber

→

Coleta 2
de onde vem o dado

→

Entendimento 3
o que há aqui dentro

→

Preparação 4
limpar e transformar

Este bloco é a etapa 2 — de onde vem o dado, e se dá para confiar nele.
O bloco 02, no notebook, mora na **3** e encosta na **4**. Juntas, são **60 a 80%** do tempo real de um projeto.

Aula 1 sobrevoou as oito etapas. Da aula 2 até a 11, descemos uma por uma.

BLOCO 1 · O MAPA

Onde os datasets vivem

🏆

Kaggle

o maior repositório aberto · `kaggle.com/datasets`

🇧🇷

dados.gov.br

portal oficial de dados abertos federais

📊

IBGE · SIDRA

censo, PNAD, IPCA — a fonte estatística do país

🔎

Brasil.io

dados públicos já limpos e normalizados

🏛️

Portal da Transparência

gastos, servidores, convênios, sanções

🤗

UCI · HuggingFace

clássicos acadêmicos e datasets de ML

Órgãos com dado bom e pouco explorado: ANAC, ANTAQ, INEP, DATASUS, TSE, ANP, INMET, Banco Central.

BLOCO 1 · KAGGLE

O que é o Kaggle

📦
Datasets
centenas de milhares, com prévia, licença e discussão

🥇
Competições
problema real, métrica pública, ranking ao vivo

📓
Notebooks
código de outras pessoas **sobre o mesmo dataset**

🎓
Learn
micro-cursos gratuitos — Pandas, viz, ML

Para esta disciplina, o recurso mais subestimado são os **notebooks públicos**:
é a leitura de código alheio que mais rápido melhora o seu.

Conta gratuita. Para baixar via API, precisa de conta verificada por telefone.

BLOCO 1 · TOUR · LEIA NESTA ORDEM

A página de um dataset, por dentro

ONDE OLHAR	O QUE PROCURAR
Data Card	origem, método de coleta, o que cada coluna significa
Aba Data	arquivos, tamanho, e a **prévia por coluna** — histograma e % de vazio
Usability	nota de 0 a 10 do **metadado** — não da qualidade do dado
License	o que você pode fazer com ele crítico
Provenance	fonte original · **quase sempre há uma**, e ela é melhor
Code	notebooks públicos: os achados e as armadilhas já mapeados
Discussion	onde alguém já reclamou do erro que você levaria 3h para achar

A prévia por coluna, na aba Data, é a melhor ferramenta gratuita de triagem que existe.

BLOCO 1 · CETICISMO

O selo de usability mente

O que ele mede

- tem descrição?
- tem licença declarada?
- as colunas têm nome legível?
- tem imagem de capa?

Metadado. Nada além disso.

O que ele *não* mede

- o dado está correto?
- a amostra representa alguém?
- as datas estão coerentes?
- alguém inventou as linhas?

Existe dataset 10.0 inteiramente sintético.

Nota alta significa **bem documentado**. Documentação boa de dado ruim continua sendo dado ruim.

BLOCO 1 · TRIAGEM · 5 MINUTOS

Oito perguntas antes de baixar

- [ ] **Quem** coletou, e por quê? Quem paga a coleta escolhe o que medir.
- [ ] **Quando**? Dado de 2015 responde perguntas de 2015.
- [ ] É a **fonte original** ou uma cópia de cópia? Suba a cadeia.
- [ ] Quantas **linhas e colunas**? Menos de 1.000 linhas limita a análise.
- [ ] Tem **mistura de tipos** — número, categoria, data, texto?
- [ ] Tem **dicionário de dados**?
- [ ] Qual a **licença**?
- [ ] É **sintético**? (variância limpa demais, zero faltantes, nomes gerados)

> Cinco minutos aqui economizam duas semanas depois.

BLOCO 1 · JURÍDICO, MAS RÁPIDO

Licença: o que serve para o trabalho

LICENÇA	SIGNIFICA	SERVE?
CC0 · Public Domain	uso livre, sem condições	sim
CC BY / CC BY-SA	livre, **citando a fonte**	sim
CC BY-NC	proibido uso comercial	sim — trabalho acadêmico
ODbL	livre, derivados sob a mesma licença	sim
"Other" / não declarada	ninguém sabe	evite
Só para a competição	uso restrito ao Kaggle	não

Regra do projeto: a licença vai citada no notebook, junto com o link da fonte. Sem isso, a entrega volta.

BLOCO 1 · LGPD

Público não quer dizer livre



Dado pessoal
identifica alguém: CPF, nome, e-mail, endereço, matrícula



Dado sensível
saúde, raça, religião, política, biometria, orientação sexual



Reidentificação
CEP + data de nascimento + sexo já identificam a maioria

> Anonimizado **não é** "tirei a coluna nome". É garantir que nenhuma **combinação** de colunas volte à pessoa.

No projeto: se houver dado pessoal, agregue ou pseudonimize — e diga o que fez, na seção de limitações. Tratamos isso a fundo na aula 17.

BLOCO 1 · A ARMADILHA

Cuidado com o dataset limpo demais

Kaggle "pronto"

- zero faltantes
- tipos já corretos
- categorias padronizadas
- sem duplicatas

Você pula direto para a etapa 5. **E não aprende as 2–4.**

Dado real

- `encoding='latin-1'`, `sep=';'`
- número com vírgula decimal
- `"—"`, `"N/D"`, `"999"` como vazio
- cabeçalho na linha 4

É onde mora 70% do trabalho — e da nota.

Escolha um dataset com **defeitos de verdade**. Consertar sujeira é conteúdo avaliado; não há mérito em limpar o que já veio limpo.

BLOCO 1 · APROVADO NA TRIAGEM? AGORA SIM

Três formas de trazer o arquivo

1 · Botão Download — para começar

```
titanic.zip → descompactar
→ pasta dados/ do projeto
```

2 · `kagglehub` — reprodutível

```python
import kagglehub, pandas as pd

p = kagglehub.dataset_download(
    "yasserh/titanic-dataset")
df = pd.read_csv(f"{p}/Titanic-Dataset.csv")
```

3 · CLI oficial — para automatizar

```
# pip install kaggle
# token em ~/.kaggle/kaggle.json

# kaggle datasets download \
#   -d yasserh/titanic-dataset --unzip
```

> As formas 2 e 3 **exigem token** e **rede**.
> Em sala usamos o CSV já baixado.

Regra do projeto: o notebook precisa rodar na máquina do professor. Versione o CSV, ou documente o download.
O nosso já está em `dados/titanic.csv` — **abram o Jupyter**.

02

Mãos na massa

Titanic · do arquivo bruto a cinco achados, sem nenhum modelo · **abram o** `aula02.ipynb`

BLOCO 2 · COMBINADO

Aqui o slide não é o palco

Este bloco acontece **dentro do Jupyter**, ao vivo, na minha tela. Abram o mesmo notebook e rodem junto.

`aula02.ipynb`
o roteiro executável — ferramental Python, anatomia do dado e o Titanic inteiro

Projetado: o notebook
a saída de verdade, com erro de verdade quando der errado

Estes slides
ficam para **consulta depois** — cada um marca uma seção do notebook

Células *Sua vez*
espalhadas pelo notebook — a gente para, vocês escrevem

Conceito que não se demonstra com dado na tela **não gruda**. Tipo de variável, faltante e cardinalidade são disso: você entende quando vê quebrar.

BLOCO 2 · ABRAM O JUPYTER

As doze seções do notebook

§	NO NOTEBOOK	SLIDE DAQUI
1	abrir o arquivo · tamanho e o que está faltando	19–22
2	o que cada coluna quer dizer	17–18
3	**quem sobreviveu?** · as 891 pessoas em pontos · sexo × classe	23–24
4	criança tinha mais chance? · histograma e faixas	26
5	o preço do bilhete · a média que mente · idade × tarifa	25
6	o que está escondido dentro do nome	26
7	sozinho ou com a família?	27
8	**a coluna 77% vazia que era ouro** · e o deck do navio	28
9	e as 177 idades que faltam?	29
10	o painel — tudo em quatro gráficos	30–31
11	**e você, teria sobrevivido?**	—
12	o validador do dataset do seu projeto	36–37

O § 11 é brincadeira séria: uma função que procura no dataset as pessoas parecidas com você e diz a chance delas. O § 12 valida o dataset que você vai propor.

BLOCO 2 · O DATASET DE HOJE

Ficha: Titanic

ORIGEM	Kaggle · competição *Titanic: Machine Learning from Disaster*
ARQUIVO	`train.csv` · 61 KB
FORMA	891 linhas × 12 colunas
UNIDADE	um passageiro
— de 2.224 a bordo: é uma	amostra
ALVO	`Survived` · 0 ou 1
LICENÇA	CC0 · domínio público
PERGUNTA	Quem tinha mais chance de sobreviver — e por quê?

É o "olá, mundo" da ciência de dados: pequeno, sujo na medida certa, e com uma pergunta que qualquer um entende.

BLOCO 2 · §2 · METADADO

O dicionário de dados

COLUNA	SIGNIFICA	TIPO DE VARIÁVEL
PassengerId	identificador sequencial	identificador
Survived	0 = morreu · 1 = sobreviveu	binária — **o alvo**
Pclass	classe do bilhete (1 / 2 / 3)	ordinal
Name · Sex · Age	nome completo, sexo, idade em anos	texto · nominal · contínua
SibSp · Parch	nº de irmãos/cônjuges · pais/filhos a bordo	discretas
Ticket · Fare	código do bilhete · tarifa paga (£ de 1912)	identificador · contínua
Cabin	número da cabine	nominal · **77% vazia**
Embarked	porto de embarque: C = Cherbourg · Q = Queenstown · S = Southampton	nominal

`Fare` é por **bilhete**, não por pessoa — e um bilhete pode cobrir a família inteira. Isso já é um achado.

BLOCO 2 · §1 · ETAPA 3 · ENTENDIMENTO

O ritual de chegada

Quatro comandos. **Sempre** estes quatro, **sempre** nesta ordem.

1. `df.shape` — cabe na memória? tenho linhas suficientes?
2. `df.head()` — o arquivo foi lido do jeito certo?
3. `df.info()` — tipos e faltantes, de uma vez só
4. `df.describe()` — a escala e a forma dos números

> Antes de qualquer gráfico, qualquer filtro, qualquer modelo. **É o cinto de segurança.**

BLOCO 2 · §1 · PASSOS 1 E 2

Carregar e olhar

```python
import pandas as pd

df = pd.read_csv("dados/titanic.csv")

print(type(df))
print(df.shape)
df.head(3)
```

```
<class 'pandas.DataFrame'>
(891, 12)

   PassengerId  Survived  Pclass  ...
0            1         0       3
1            2         1       1
2            3         1       3

[3 rows x 12 columns]
```

`read_csv` tem **50 parâmetros**. `sep`, `encoding`, `na_values`, `parse_dates`, `decimal` — cada um salva um dia de trabalho. Aula 4.

BLOCO 2 · §1 · PASSO 3 · O MAIS DENSO

`df.info()` — leia as três colunas

```
 #   Column       Non-Null Count  Dtype
---  ------       --------------  -----
 0   PassengerId  891 non-null    int64
 1   Survived     891 non-null    int64
 2   Pclass       891 non-null    int64
 3   Name         891 non-null    object
 4   Sex          891 non-null    object
 5   Age          714 non-null    float64   ←  177 faltando
 6   SibSp        891 non-null    int64
 7   Parch        891 non-null    int64
 8   Ticket       891 non-null    object
 9   Fare         891 non-null    float64
 10  Cabin        204 non-null    object    ←  687 faltando (77%)
 11  Embarked     889 non-null    object    ←  2 faltando
memory usage: 83.7+ KB
```

891 é o total. Todo número menor que ele é um buraco — e cada buraco é uma decisão que você vai ter que tomar e justificar.

BLOCO 2 · §1 · ALÉM DO INFO()

O perfil que eu monto em todo projeto

```
perfil = pd.DataFrame({
    "dtype": df.dtypes,
    "distintos": df.nunique(),
    "faltantes": df.isna().sum(),
    "%": (df.isna().mean()*100).round(1),
})
perfil
```

Cardinalidade denuncia o tipo:
2 distintos → binária · 891 → identificador

	distintos	falta	%
PassengerId	891	0	0.0
Survived	2	0	0.0
Pclass	3	0	0.0
Name	891	0	0.0
Sex	2	0	0.0
Age	88	177	19.9
SibSp	7	0	0.0
Ticket	681	0	0.0
Fare	248	0	0.0
Cabin	147	687	77.1
Embarked	3	2	0.2

`Ticket`: 681 distintos em 891 linhas. Bilhetes se repetem — **pessoas viajavam juntas**. Outro achado de graça.

Quem sobreviveu?

```python
df.groupby("Sex")["Survived"].mean()

df.groupby("Pclass")["Survived"].mean()

pd.pivot_table(df, values="Survived",
               index="Sex", columns="Pclass",
               aggfunc="mean")
```

```
Sex
female    0.742
male      0.189

Pclass
1    0.630
2    0.473
3    0.242

Pclass      1      2      3
Sex
female  0.968  0.921  0.500
male    0.369  0.157  0.135
```

Três linhas de código. Mulher na 1ª classe: 96,8%. Homem na 3ª: 13,5%. **Sete vezes.**

BLOCO 2 · §3 · DISCIPLINA

Taxa sem n é propaganda

```
df.groupby(["Sex", "Pclass"])["Survived"] \
  .agg(n="count", taxa="mean")
```

Sex	Pclass	n	taxa
female	1	94	0.968
	2	76	0.921
	3	144	0.500
male	1	122	0.369
	2	108	0.157
	3	347	0.135

Uma taxa de 100% sobre 3 casos
não é um achado — é ruído com cara de achado

Homens na 3ª classe: 347 pessoas
39% de todo o dataset em uma única célula

Grupo desbalanceado
volta a nos assombrar na aula 14, na classificação

Todo `mean()` vem acompanhado de `count()`. **Sempre.** É a regra mais barata de aprender e a mais cara de ignorar.

A média que mente

	Age	Fare
count	714.00	891.00
mean	29.70	32.20
std	14.53	49.69
min	0.42	0.00
25%	20.12	7.91
50%	28.00	14.45
75%	38.00	31.00
max	80.00	512.33

Fare: média 32,20 · mediana 14,45
a média é mais que o **dobro** da mediana

Metade pagou menos de £14,45
e alguém pagou £512 — 35× a mediana

Distribuição assimétrica
a média não descreve ninguém: nem o pobre, nem o rico

`Fare` mínimo = **0,00**. Tripulação? Cortesia? Erro de registro? **Os dados não dizem** — e isso vai para as limitações.

O dado que já estava lá

```python
# texto livre → categoria
df["Titulo"] = (df["Name"]
    .str.extract(r",\s*([^\.]+)\."))

# duas colunas → uma ideia
df["Familia"] = df["SibSp"] + df["Parch"] + 1

# contínua → ordinal
df["Faixa"] = pd.cut(df["Age"],
    bins=[0, 12, 18, 35, 60, 100],
    labels=["criança", "adolesc.",
            "adulto jovem", "adulto",
            "idoso"])
```

```
Titulo
Mr        517
Miss      182
Mrs       125
Master     40
Dr          7

Faixa           n   taxa
criança        69  0.580
adolescente    70  0.429
adulto jovem  358  0.383
adulto        195  0.400
idoso          22  0.227
```

Feature engineering: criar colunas que ainda não existem a partir das que existem. Aqui, texto virou categoria e idade virou faixa.

BLOCO 2 · §7 · ACHADO Nº 4

Nem toda relação é uma reta

Familia	n	taxa	
1	537	0.304	
2	161	0.553	
3	102	0.578	
4	29	0.724	← pico
5	15	0.200	
6	22	0.136	
7	12	0.333	
8	6	0.000	
11	7	0.000	

📈

Sobe até 4, despenca depois

família pequena ajuda · família grande atrapalha

⚠️

Mas olhe o *n*

famílias de 8 e 11: 6 e 7 pessoas. **Não conclua nada.**

🤔

E cuidado com a causa

família grande viajava na 3ª classe. É o tamanho ou é a classe?

Correlação encontrada ≠ causa encontrada. Separar as duas é **a aula 7** — e é o que mais derruba projeto final.

BLOCO 2 · §8 · O MOMENTO DA AULA

77% vazia — jogar fora?

```python
tem_cabine = df["Cabin"].notna()

df.groupby(tem_cabine)["Survived"] \
  .agg(["count", "mean"])
```

```
       count   mean
Cabin
False    687  0.300
True     204  0.667
```

💡

Quem tem cabine registrada sobreviveu 2,2× mais

0,667 contra 0,300

🧠

A ausência não é aleatória

é o terceiro tipo de faltante (§8 do notebook): falta *porque* a pessoa era de 3ª classe

⚒️

A coluna certa é `tem_cabine`

booleana, 0% faltante, e informativa

`dropna()` teria apagado **o segundo achado mais forte do dataset**.

BLOCO 2 · §9 · A DECISÃO

177 idades faltando. E agora?

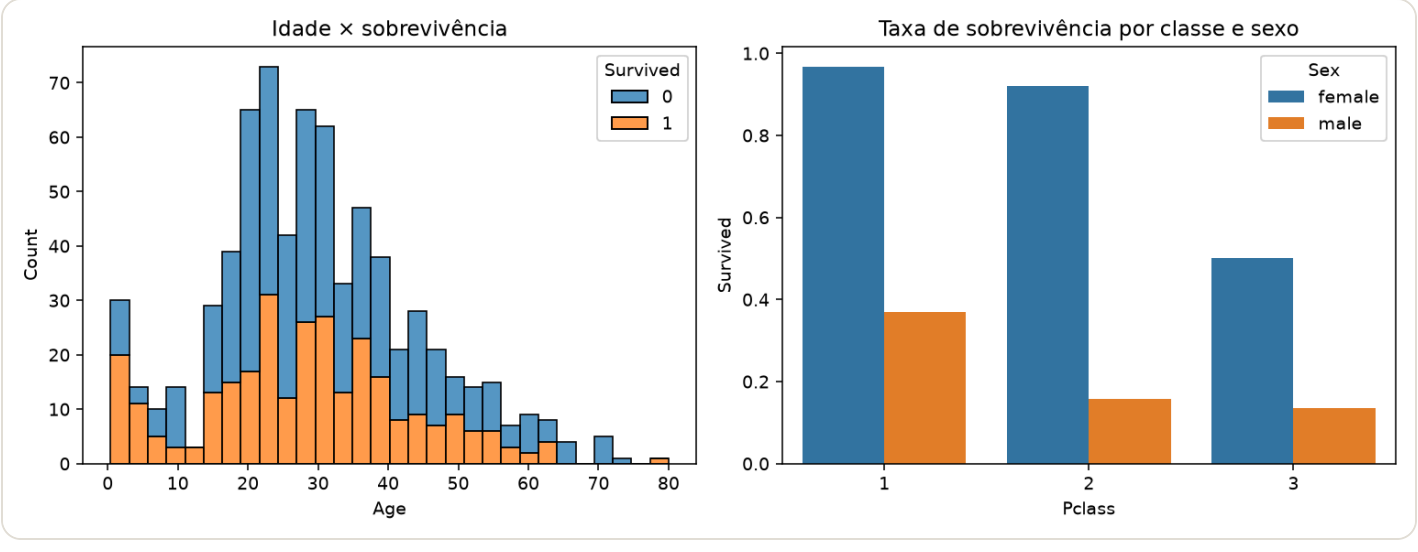
OPÇÃO	O QUE ACONTECE	CUSTO
A · descartar	891 → **714 linhas**	perde 20% da amostra — e não ao acaso
B · média (29,7)	mantém 891	achata a variância; dá 29,7 anos a bebês
C · mediana por título	mantém 891, respeita o grupo	mais código — e é a melhor

```
Titulo    n   mediana
Mr      398      30.0
Miss    146      21.0
Mrs     108      35.0
Master   36       3.5   ←  "Master" era como se chamava um MENINO
```

A opção B daria **29,7 anos** a cada Master. A opção C dá **3,5**. O nome carregava a idade o tempo todo.

BLOCO 2 · §10 · ETAPA 5 · EXPLORAÇÃO

Do número ao gráfico



À esquerda, a barra de crianças é a única em que o laranja domina. À direita, o abismo entre as barras é a história inteira do naufrágio.

§10 do notebook. Matplotlib e Seaborn a fundo nas aulas 8 e 9 — hoje o gráfico é só a última etapa da leitura.

BLOCO 2 · BALANÇO

Cinco achados. Nenhum modelo.

1. Sexo e classe explicam quase tudo: **96,8% × 13,5%**.
2. A coluna 77% vazia era **informação**, não lixo: 0,67 × 0,30.
3. Família ajuda **até 4 pessoas** — depois vira risco.
4. O nome carregava a idade: **Master = 3,5 anos**.
5. A média da tarifa **não descreve ninguém**.

Tudo isso com `read_csv`, `info`, `describe`, `groupby` e `cut`. **É o que se espera do seu projeto.**

03

O trabalho

O projeto que atravessa o semestre — e responde pelas duas notas

BLOCO 3 · A TAREFA

O trabalho, em uma frase

PROJETO FINAL

escolher um **dataset público real**, formular **três perguntas de negócio** e respondê-las percorrendo o pipeline inteiro — **incluindo o que você não conseguiu responder**.

Até 3 pessoas
individual, dupla ou trio — **trio é o teto**

Relatório SBC
artigo no template oficial da SBC, em PDF

2 entregas
setembro e novembro

Nota 1 + Nota 2
não há apresentação — o texto fala por vocês

Comece na semana 2. Quem começa na semana 12 entrega notebook com gráfico bonito — não entrega projeto.

BLOCO 3 · O CALENDÁRIO QUE IMPORTA

Duas entregas, duas notas

1️⃣ Etapa 1 · Nota 1

- prazo: **fim de setembro**
- seções **1 a 4** do relatório
- pergunta · dados · entendimento · preparação
- **4 a 6 páginas** no template SBC
- o dado tem que estar **carregado e limpo**

2️⃣ Etapa 2 · Nota 2

- prazo: **fim de novembro**
- **o relatório completo** — seções 1 a 7
- com as seções 1–4 **corrigidas** conforme o retorno
- **8 a 12 páginas** no template SBC
- é o trabalho que fica no seu portfólio

A Etapa 2 **não é um anexo** da Etapa 1: é o documento inteiro, reescrito. O que eu apontei em setembro e continuou igual em novembro **conta duas vezes contra**.

BLOCO 3 · ENTREGÁVEIS · NAS DUAS ETAPAS

Três artefatos. Sem apresentação.



Relatório em PDF · template SBC

é *o* trabalho — artigo científico, com resumo, seções numeradas, figuras com legenda e referências



Notebook `projeto.ipynb`

a evidência do que o relatório afirma — narrado em markdown e **reproduzível do zero**



Repositório Git

relatório + notebook + `requirements.txt` + `README.md` + os dados (ou o script que os baixa)

O teste: clono o repositório, crio o ambiente, faço *Restart & Run All* — e confiro se os números do PDF são **os mesmos** que saíram do notebook.
Número no texto que não sai do código é **invenção**, e derruba a nota da etapa inteira.

Template SBC: modelo oficial para artigos (LaTeX no Overleaf ou `.docx`), disponível no site da SBC. Escolham o formato hoje, não em novembro.

BLOCO 3 · ESCOLHA DO DATASET · REQUISITOS DUROS

O que o seu dataset precisa ter

REQUISITO	MÍNIMO — NÃO NEGOCIÁVEL	POR QUÊ
Tamanho	**≥ 1.000 registros**, *sem* as duplicatas exatas	menos que isso, todo grupo vira ruído
Largura	**≥ 10 colunas** de conteúdo — identificador não conta	cruzar variáveis pede espaço
Numéricas	**≥ 3**, sendo **≥ 1 contínua**	média, dispersão, correlação
Categóricas	**≥ 3**, sendo **≥ 1 com mais de 5 categorias**	`groupby` além de dois grupos
Temporal	**≥ 1 data**, cobrindo **≥ 12 meses**	sem tempo não há recorte temporal
Texto	**≥ 1 coluna** de texto livre ou alta cardinalidade	extrair o dado escondido (§8)
Sujeira	**≥ 1 coluna com 5% a 50% de faltantes**	limpar vale 40% da Etapa 1

Mais dois, que nenhum código verifica: uma coluna que sirva de **alvo** para o modelo da Etapa 2, e **fonte** — pública, com licença declarada e URL estável.
Todos valem ao mesmo tempo. Falhou em um, não é "quase" aprovado: é reprovado.

BLOCO 3 · ESCOLHA DO DATASET · VETO E PROVA

Proibidos — e como provar que o seu passa

🚫 Vetados

- **Titanic**, Iris, Wine, Boston Housing, MNIST — e qualquer *toy dataset* do `sklearn`
- sintéticos, "*fake data*" ou **gerados por IA**
- o dataset **já reservado** por outro grupo — vale a ordem de chegada na aula 3
- dado pessoal identificável sem agregar ou pseudonimizar
- o "Kaggle limpo": zero faltantes, tudo padronizado

```
$ python valida_dataset.py meu.csv

  registros ............... 4812   OK
  colunas úteis ............. 14   OK
  numéricas ..... 5 (2 contínuas)   OK
  categóricas . 4 (1 com >5 cat.)   OK
  coluna temporal ..... 38 meses    OK
  texto livre ................. 2   OK
  faltantes 5–50% ............. 3   OK
  ------------------------------
  APROVADO
```

§11 do notebook de hoje. Rode **antes** de propor.

Dataset brasileiro ganha meio ponto extra. São mais sujos, menos explorados — e é onde vocês vão trabalhar.

BLOCO 3 · O QUE SEPARA 6 DE 10

Pergunta de negócio × curiosidade

- ✗ "Analisar o dataset de vendas."
- ✗ "Qual a média de idade dos clientes?" — *isso é uma consulta, não uma pergunta*
- ✗ "Aplicar machine learning nos dados." — *o modelo é meio, não fim*
- ✓ "Que características de cliente antecipam o cancelamento em 90 dias — e com que antecedência dá para agir?" ✓

Boa pergunta: tem **sujeito**, tem **recorte de tempo**, e a resposta **muda uma decisão**.

Teste: se a resposta for "ok, interessante" e ninguém fizer nada diferente — a pergunta era fraca.

BLOCO 3 · MOLDE · O SUMÁRIO OBRIGATÓRIO

As sete seções — e onde a linha passa

1	**Introdução** — contexto e as 3 perguntas, antes de qualquer número	etapa 1
2	**Os dados** — fonte, licença, dicionário, unidade de observação	etapa 1
3	**Entendimento** — ritual de chegada, perfil de colunas, qualidade	etapa 1
4	**Preparação** — limpeza e derivadas, **com a justificativa de cada escolha**	etapa 1
5	**Exploração** — estatística e gráficos que respondem às 3 perguntas	etapa 2
6	**Modelagem** — ao menos um modelo, com *baseline* e métrica	etapa 2
7	**Conclusão e limitações** — as respostas, e onde elas não valem	etapa 2

Entrega 1 = seções 1 a 4 (mais resumo e referências). **Entrega 2 = as sete**, com as quatro primeiras revisadas.

BLOCO 3 · A SEÇÃO QUE EU LEIO PRIMEIRO

Limitações

Não é humildade decorativa. É **a parte mais profissional do trabalho**.

Quem ficou de fora
a amostra representa quem? e quem ela nunca viu?

O que você assumiu
cada imputação e cada exclusão é uma hipótese

Correlação sem causa
o que você *não* pode afirmar com esses dados

Validade temporal
até quando essa conclusão se sustenta?

Trabalho sem limitações reais leva teto de nota. **Não existe análise sem limitação** — quem não achou, não procurou.

BLOCO 3 · CRITÉRIOS · CADA ETAPA VALE 100 PONTOS

Como cada entrega é avaliada

CRITÉRIO	O QUE SE OLHA	ETAPA 1	ETAPA 2
Perguntas	relevância, clareza e recorte das três	20%	10%
Dados e fonte	fonte, licença, dicionário, unidade de observação	20%	5%
Tratamento dos dados	limpeza **justificada**, derivadas com propósito	40%	15%
Análise e visualização	as respostas se sustentam? os gráficos comunicam?	—	25%
Modelagem	escolha adequada, *baseline*, métrica bem lida	—	15%
Limitações	honestidade e profundidade	—	15%
Reprodutibilidade	clonar → instalar → *Run All* → os números batem	10%	10%
Texto e formato SBC	redação, figuras com legenda, citações, referências	10%	5%

Repare: na Etapa 1, **tratamento de dados vale 40%**. Modelagem, na Etapa 2, vale 15%. Os pesos seguem o esforço real da profissão — não o que é mais divertido.

BLOCO 3 · MARCOS

Não deixe para a última semana

Aula 3	**Proposta**	grupo (até 3), dataset com link e licença, saída do validador, 3 perguntas
Aula 6	**Checkpoint 1**	dados carregados, dicionário escrito, perfil de colunas pronto
Aulas 8–9	**Oficina**	**duas aulas inteiras** para escrever as seções 1 a 4, com atendimento por grupo
Setembro	**Entrega 1**	**Nota 1** · relatório SBC com as seções 1 a 4 + notebook + repositório
Aula 12	**Checkpoint 2**	EDA feita — as 3 perguntas já têm respostas preliminares
Aula 14	**Checkpoint 3**	modelo rodando, com *baseline* e métrica escolhida
Aulas 15–18	**Oficina**	**quatro aulas**: exploração → modelagem → escrita → reprodutibilidade
Novembro	**Entrega 2**	**Nota 2** · relatório completo, seções 1 a 7, com as quatro primeiras revisadas

Seis das dezoito aulas são oficina — o trabalho se faz em sala, comigo por perto. As datas exatas estão no plano de ensino; os checkpoints não valem nota isolada, mas quem chega sem eles perde o direito à orientação.

BLOCO 3 · ANTIPADRÕES · VISTOS TODO SEMESTRE

Os cinco jeitos de se dar mal

1️⃣

Escolher o dataset na véspera da Etapa 1

não sobra tempo para limpar — e limpeza é 40% da nota da etapa

2️⃣

Fazer o modelo primeiro

acurácia de 0,94 sem *baseline* não significa absolutamente nada

3️⃣

Relatório que não bate com o notebook

número no PDF que o código não produz é invenção — e eu confiro

4️⃣

Caminho absoluto

`C:/Users/joao/Downloads/…` — não roda na minha máquina, é zero

5️⃣

Colar saída de IA sem entender

texto genérico, sem os *seus* números, se reconhece de longe — e vale zero

FECHAMENTO

Se você esquecer tudo, lembre destas três

1. Todo dataset é um **recorte**. Pergunte sempre quem ficou de fora.

2. `dtype` é armazenamento; **tipo de variável é significado**. Não confunda.

3. O **ritual de chegada** antes de tudo — e todo `mean()` vem com `count()`.

ATÉ A PRÓXIMA AULA

Para fazer em casa

1 · Escolha o dataset
passe as 8 perguntas de triagem · traga o link e a licença

2 · Rode o validador
§11 do notebook · no *seu* dataset · traga a saída impressa

3 · Rascunhe 3 perguntas
com sujeito, recorte de tempo e decisão associada

4 · Entregue a Lista 1
a lista de exercícios da aula 1 · até o início da aula 3

Próxima aula: NumPy e o fim do laço explícito.
Vou medir na frente de vocês o custo de iterar linha a linha — tragam café.

O `aula02.ipynb` e o `titanic.csv` estão na pasta da aula. Rode, quebre, mude os `bins` do `cut`.