PROGRAMAÇÃO PARA CIÊNCIA DE DADOS · 2026.1

O trabalho

Um dataset público real, três perguntas e um relatório — duas entregas, as duas notas do semestre

PROJETO FINAL • ATÉ 3 PESSOAS • SETEMBRO E NOVEMBRO

O TRABALHO · A TAREFA

O trabalho, em uma frase

PROJETO FINAL

escolher um **dataset público real**, formular **três perguntas de negócio** e respondê-las percorrendo o pipeline inteiro — **incluindo o que você não conseguiu responder**.

Até 3 pessoas
individual, dupla ou trio — **trio é o teto**

Relatório SBC
artigo no template oficial da SBC, em PDF

2 entregas
setembro e novembro

Nota 1 + Nota 2
não há apresentação — o texto fala por vocês

O TRABALHO · O CALENDÁRIO QUE IMPORTA

Duas entregas, duas notas

1️⃣ Etapa 1 · Nota 1

- prazo: **fim de setembro**
- seções **1 a 4** do relatório
- pergunta · dados · entendimento · preparação
- **4 a 6 páginas** no template SBC
- o dado tem que estar **carregado e limpo**

2️⃣ Etapa 2 · Nota 2

- prazo: **fim de novembro**
- **o relatório completo** — seções 1 a 7
- com as seções 1–4 **corrigidas** conforme o retorno
- **8 a 12 páginas** no template SBC
- é o trabalho que fica no seu portfólio

O TRABALHO · ENTREGÁVEIS · NAS DUAS ETAPAS

O que vocês me entregam

Relatório em PDF · template SBC
é o trabalho — artigo científico, com resumo, seções numeradas, figuras com legenda e referências

Notebook `projeto.ipynb`
a evidência do que o relatório afirma — narrado em markdown, e roda do começo ao fim sem erro

Os dados
o arquivo que vocês usaram, junto do notebook — ou o link de onde ele foi baixado

O teste: abro o notebook de vocês, faço *Restart & Run All* — e confiro se os números do PDF são **os mesmos** que saíram dali.
Número no texto que não sai do código é **invenção**, e derruba a nota da etapa inteira.

Template SBC — o ZIP baixa direto daqui:
`www.sbc.org.br/wp-content/uploads/2024/07/modelosparapublicaodeartigos.zip`
Vem em `.docx` e em LaTeX. **Escolham o formato hoje**, não em novembro.

01

Escolher o dataset

Onde procurar · como escolher · os mínimos que o seu tem que cumprir · dois exemplos rodados de verdade

ESCOLHER O DATASET · SUGESTÕES

Onde procurar

🇧🇷

Portal brasileiro de dados abertos

tudo que os órgãos federais publicam, num lugar só — saúde, educação, transporte, gastos públicos

`dados.gov.br/dados/conjuntos-dados`

🏆

Kaggle

o maior acervo aberto do mundo, de qualquer assunto — com prévia das colunas e a licença declarada em cada dataset

`kaggle.com/datasets`

🌐

Qualquer outra fonte

vale, **desde que a licença permita uso aberto** — procure a palavra *licença* na página do dataset e copie o nome dela para o relatório. Sem licença declarada, escolha outro.

ESCOLHER O DATASET · O QUE FUNCIONA

Escolha um assunto que você aguente

Vocês vão conviver com esse dataset por **quatro meses**. Escolha por interesse, não por conveniência.

💡 Boas pistas

- o setor **onde você trabalha** ou quer trabalhar
- um assunto que você já acompanha por conta própria
- uma pergunta que você sempre quis responder
- a sua cidade, o seu estado, o seu curso

🚫 Proibidos

- **Titanic**, Iris, Wine, Boston Housing, MNIST
- qualquer *toy dataset* de biblioteca (`sklearn`, `seaborn`)
- dados sintéticos ou gerados por IA
- o dataset já reservado por outro grupo

Os proibidos são os **fáceis demais**: já vêm limpos, já foram analisados mil vezes, e não sobra trabalho nenhum para você mostrar.

ESCOLHER O DATASET · REQUISITOS DUROS

O que o seu dataset precisa ter

REQUISITO	MÍNIMO	O QUE CONTA COMO ISSO
Tamanho	**≥ 2.000 linhas**	7.889 deputados · 12.400 voos · 5.300 escolas
Largura	**≥ 10 colunas**	colunas de conteúdo — `id` e `código` não contam
Numéricas	**≥ 3**, com **1 contínua**	**contínua:** preço, distância, salário, nota **não conta como contínua:** nº de filhos, nº de quartos
Categóricas	**≥ 3**, com **1 de mais de 5**	sexo (2) · situação (3) · **estado (27)** ← essa é a de mais de 5
Temporal	**≥ 1 data**, **≥ 12 meses**	data de nascimento · data da compra · data do voo
Texto	**≥ 1 coluna**	nome, endereço, descrição, nome do município
Sujeira	**≥ 1 coluna 5% a 50% vazia**	"12% dos deputados sem estado de nascimento"

Mais dois que nenhuma conta verifica: uma coluna que sirva de **alvo** para o modelo da Etapa 2, e **fonte pública com licença declarada**.

ESCOLHER O DATASET · QUATRO COMANDOS, RODADOS NO DATASET DOS DEPUTADOS

Como conferir se ele cumpre

`df.shape` → tamanho e largura

```
(7889, 13)
```

7.889 linhas ✓ (mínimo 2.000) · 13 colunas ✓

`df.dtypes` → número ou texto

```
str        10
int64       2
float64     1
```

3 numéricas ✓ · `str` pode ser categoria ou texto — o `nunique` decide

`df.nunique()` → categórica ou contínua

```
siglaSexo           2
ufNascimento       28
municipio        1460
nome             7550
```

2 e 28 = categóricas ✓ · 7.550 em 7.889 linhas = texto, quase tudo diferente

`df.isna().mean()` → a sujeira

```
cpf             1.000
ufNascimento    0.122
dataNascimento  0.113
siglaSexo       0.000
```

0,122 = 12,2% vazio ✓ (a faixa é 0,05 a 0,50) · `cpf` está **100% vazia**: não serve para nada

---

Se vier tudo numa coluna só: `sep=";"` · acento quebrado: `encoding="latin-1"` · número virou texto: `decimal=","`

ESCOLHER O DATASET · EXEMPLO 1 · RODADO DE VERDADE

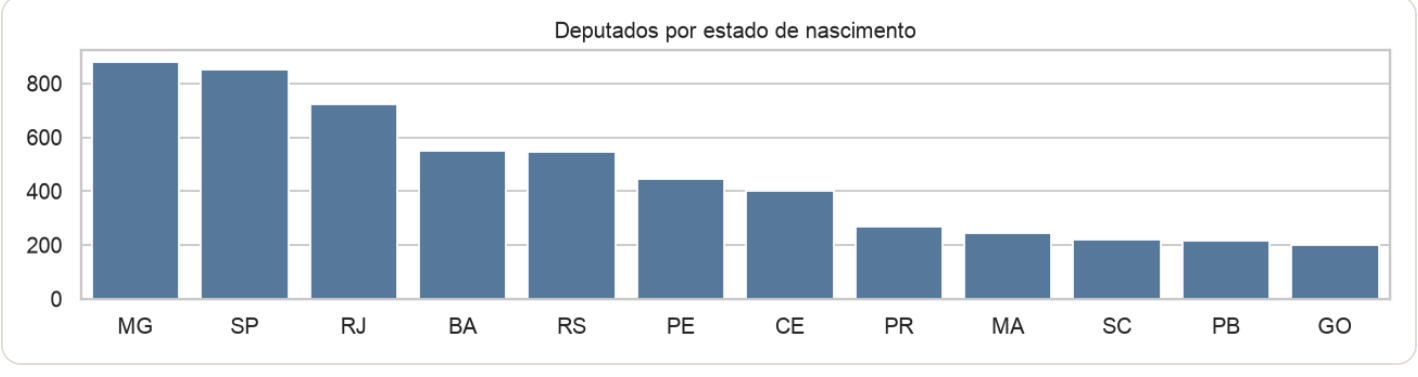
Deputados federais · dados abertos da Câmara

```python
df = pd.read_csv(
    "deputados.csv", sep=";")

df.shape
df["ufNascimento"].value_counts()
```

```
(7889, 13)

MG    881
SP    850
RJ    722
BA    551
RS    544
```



7.889 linhas, 13 colunas, com data de nascimento, UF, sexo e nome — e **893 datas faltando**.

`dadosabertos.camara.leg.br/arquivos/deputados/csv/deputados.csv`

ESCOLHER O DATASET · EXEMPLO 2 · RODADO DE VERDADE

Táxis de Nova York · sem baixar nada

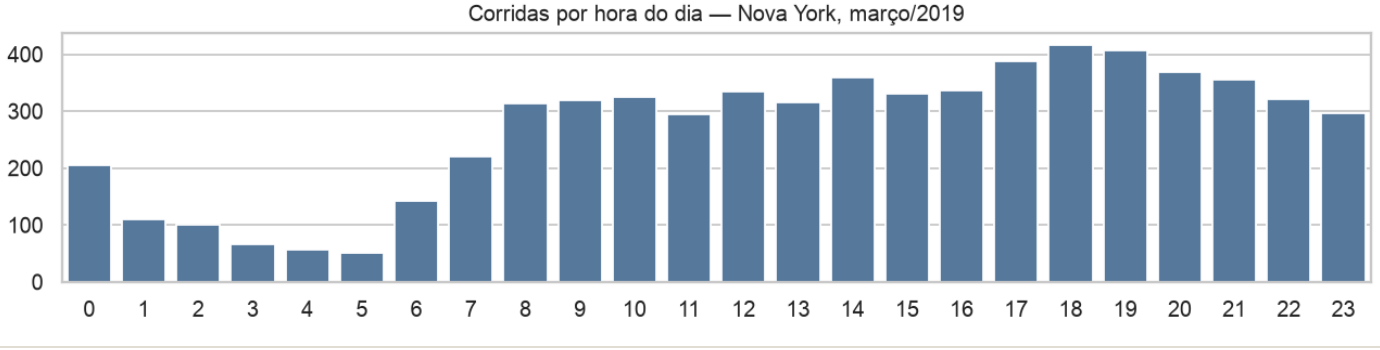
```python
import seaborn as sns

df = sns.load_dataset("taxis")

df.shape
df.groupby("payment")["tip"].mean()
```

```
(6433, 14)

payment
cash           0.00
credit card    2.78
```



Gorjeta média **zero** em dinheiro? Ninguém é pão-duro: o sistema **não registra** gorjeta em espécie. Vazio e zero não são a mesma coisa.

Serve para treinar, não serve para o projeto — vem com o `seaborn`, e dataset de biblioteca está na lista dos proibidos.

02

Escrever o relatório

A pergunta · a estrutura obrigatória · as limitações · como cada entrega é avaliada

O TRABALHO · VALE 20% DA ETAPA 1

Pergunta de negócio × curiosidade

- ✗ "Analisar o dataset de vendas."
- ✗ "Qual a média de idade dos clientes?" — *isso é uma consulta, não uma pergunta*
- ✗ "Aplicar machine learning nos dados." — *o modelo é meio, não fim*
- ✓ "Que características de cliente antecipam o cancelamento em 90 dias — e com que antecedência dá para agir?" ✓

Boa pergunta: tem **sujeito**, tem **recorte de tempo**, e a resposta **muda uma decisão**.

Teste: se a resposta for "ok, interessante" e ninguém fizer nada diferente — a pergunta era fraca.

O TRABALHO · MOLDE · O SUMÁRIO OBRIGATÓRIO

As sete seções — e onde a linha passa

1	**Introdução** — contexto e as 3 perguntas, antes de qualquer número	etapa 1
2	**Os dados** — fonte, licença, dicionário, unidade de observação	etapa 1
3	**Entendimento** — o que há no arquivo: tamanho, tipos, quanto está vazio, quantos valores distintos, e os defeitos que vocês acharam	etapa 1
4	**Preparação** — limpeza e derivadas, **com a justificativa de cada escolha**	etapa 1
5	**Exploração** — estatística e gráficos que respondem às 3 perguntas	etapa 2
6	**Modelagem** — ao menos um modelo, com *baseline* e métrica	etapa 2 · aula 12
7	**Conclusão e limitações** — as respostas, e onde elas não valem	etapa 2

Entrega 1 = seções 1 a 4 (mais resumo e referências). **Entrega 2 = as sete**, com as quatro primeiras revisadas.

O TRABALHO · CRITÉRIOS · CADA ETAPA VALE 100 PONTOS

Como cada entrega é avaliada

CRITÉRIO	O QUE SE OLHA	ETAPA 1	ETAPA 2
Perguntas	relevância, clareza e recorte das três	20%	10%
Dados e fonte	fonte, licença, dicionário, unidade de observação	20%	5%
Tratamento dos dados	limpeza **justificada**, derivadas com propósito	40%	15%
Análise e visualização	as respostas se sustentam? os gráficos comunicam?	—	25%
Modelagem	escolha adequada, *baseline*, métrica bem lida	—	15%
Limitações	honestidade e profundidade	—	15%
Reprodutibilidade	abrir → *Run All* → roda sem erro e os números batem	10%	10%
Texto e formato SBC	redação, figuras com legenda, citações, referências	10%	5%

Repare: na Etapa 1, **tratamento de dados vale 40%**. Modelagem, na Etapa 2, vale 15%. Os pesos seguem o esforço real da profissão — não o que é mais divertido.