PROGRAMAÇÃO PARA CIÊNCIA DE DADOS · 2026.1

Cronograma do semestre

19 encontros de ~3h20 · 60h · 4 créditos — **12 aulas de conteúdo**, **6 de oficina** e **1 em aberto**, duas entregas

Calendário oficial da disciplina: sextas de 31/07 a 25/09 (aulas 1 a 9) e **quintas** de 01/10 a 03/12 (aulas 10 a 19) · exame em 10/12. **Nenhum feriado, nacional ou do RS, cai em dia de aula. As aulas 8–9 e 15–18 são oficina:** os grupos executam o trabalho em sala, com você circulando. O conteúdo que ocupava esses seis encontros foi realocado — o mapa está no fim do documento.

Oficina do trabalho · Entrega avaliada · Marco (sem nota isolada) · Lista de exercícios · Prova prática

INTRODUÇÃO E FUNDAMENTOS

aulas 1–2 · panorama, pipeline, ferramental

01	31/07	**Introdução, pipeline e primeiro projeto** panorama da área · as 7 etapas do pipeline · Python idiomático · projeto do táxi de NY, ponta a ponta	política de IA
02	07/08	**Datasets** onde os datasets vivem e como se avalia um · Titanic no notebook: ferramental, anatomia e qualidade do dado · **o projeto final em detalhe**	Lista 1 você está aqui

MANIPULAÇÃO, ANÁLISE E VISUALIZAÇÃO

aulas 3–7 · NumPy, Pandas, estatística, gráficos

03	14/08	**NumPy e o fim do laço explícito** ndarray · vetorização medida com `%timeit` ao vivo · broadcasting · view vs cópia	Proposta do projeto grupo (até 3), dataset, licença, tamanho, 3 perguntas
04	21/08	**Pandas: fundamentos** Series, DataFrame e o índice · `read_csv` e os parâmetros que salvam o dia · `.loc` × `.iloc` · `SettingWithCopyWarning`	
05	28/08	**Limpeza e transformação** faltantes e imputação · duplicatas e tipos · datas e texto · colunas derivadas · outliers — e quando *não* remover	Lista 2
06	04/09	**Agregação, combinação e o primeiro gráfico** `groupby` e o split-apply-combine · `merge`/`concat` · `pivot_table`/`melt` · séries temporais · **Matplotlib: Figure/Axes, os cinco gráficos, escalas, subplots**	Checkpoint 1 dados carregados, dicionário escrito, perfil de colunas pronto
07	11/09	**Estatística descritiva e comunicação visual** tendência central e dispersão · distribuições · Pearson × Spearman e o quarteto de Anscombe · correlação ≠ causalidade · viés e Simpson · **Seaborn estatístico, paletas, razão dado-tinta, como um gráfico mente**	Lista 3 aula longa — e o bloco onde a turma mais tropeça

TRABALHO 1 · OFICINA

aulas 8–9 · os grupos executam a Etapa 1 em sala

08	18/09	**Oficina do Trabalho 1 · I** cada grupo escreve as seções 1 a 4 no seu próprio dataset · atendimento grupo a grupo · mini-clínicas por demanda: leitura do arquivo, dicionário de dados, limpeza justificada	oficina não é aula expositiva — venham com o notebook rodando
09	25/09	**Oficina do Trabalho 1 · II** fechamento das seções 1–4 · o template SBC na prática · **revisão cruzada**: cada grupo lê o relatório de outro · **teste de reprodutibilidade**: clonar o repositório do colega e rodar	oficina · Entrega 1 · Nota 1 prazo **30/09** · relatório SBC seções 1–4 + notebook + repositório

AQUISIÇÃO E CONSOLIDAÇÃO

aulas 10–11 · SQL, APIs, scraping, ética, prova prática

10	01/10	**De onde vêm os dados — e o que não se pode fazer com eles** SQL a partir do Python · APIs REST e JSON aninhado · scraping, robots.txt e termos de uso · CSV × Parquet × JSON · **viés algorítmico, LGPD e limites epistêmicos: o que dado nenhum consegue afirmar**	devolutiva da Entrega 1
11	08/10	**Estudo de caso + prova prática** 1ª metade: análise completa ao vivo, de um dataset novo · 2ª metade: prova de 90 min, notebook, com consulta	Prova prática cobre as aulas 1–10

MACHINE LEARNING

aulas 12–14 · fundamentos, validação, regressão, classificação, não supervisionado

12	15/10	**Fundamentos de ML e validação** supervisionado × não supervisionado · overfitting e viés/variância · `train_test_split` · a API do scikit-learn · KNN · **validação cruzada k-fold e estratificada** · **vazamento de dados, demonstrado ao vivo** · `Pipeline` como defesa estrutural	Lista 4 · Checkpoint 2 EDA feita — as 3 perguntas já têm respostas preliminares
13	22/10	**Regressão e ajuste de modelos** linear simples e múltipla · MAE, RMSE, R^2 · `StandardScaler`, `OneHotEncoder`, `ColumnTransformer` · Ridge, Lasso e Random Forest · **`GridSearchCV` e `RandomizedSearchCV`** · **curvas de aprendizado** · seleção de features	
14	29/10	**Classificação, não supervisionado e produção** regressão logística, árvores e ensembles · matriz de confusão, precisão × recall, ROC/AUC, base desbalanceada · **k-means e a escolha de k, PCA, detecção de anomalias** · **serialização, MLOps, FastAPI e *drift***	Lista 5 · Checkpoint 3 **a aula mais longa do semestre** · modelo rodando, com *baseline* e métrica

TRABALHO FINAL · OFICINA

aulas 15–18 · os grupos executam a Etapa 2 em sala

15	05/11	**Oficina do Trabalho Final · I — exploração** a EDA que *responde às três perguntas*, não a que enfeita · escolha do modelo e definição do *baseline* · atendimento por grupo	oficina
16	12/11	**Oficina do Trabalho Final · II — modelagem** treino, métrica e validação no dataset de cada grupo · clínica de vazamento de dados · leitura crítica do resultado: métrica boa demais quase sempre é erro	oficina
17	19/11	**Oficina do Trabalho Final · III — escrita** conclusões que respondem às perguntas · **a seção de limitações** · figuras com legenda, citações e referências no padrão SBC · revisão cruzada entre grupos	oficina
18	26/11	**Oficina final e encerramento** teste de reprodutibilidade cruzado: clonar, instalar, *Run All* no trabalho de outro grupo · ajustes finais · erros recorrentes da turma · encerramento e trilha de estudo	oficina · Entrega 2 · Nota 2 prazo **30/11** · relatório completo, seções 1–7, com as anteriores revisadas
19	03/12	**Encontro em aberto** o calendário oficial tem **19 datas** e o plano tem 18 aulas — este encontro ainda não tem destino. Sugestões: revisão para o exame de 10/12 · devolutiva dos trabalhos · uma aula de conteúdo que tenha estourado o tempo	decidir
–	10/12	**Exame** conforme o calendário oficial da disciplina	

A trilha do projeto, isolada

aula 3 · 14/08
Proposta
grupo de até 3, dataset com link e licença, tamanho do dataset e 3 perguntas rascunhadas — meia página

aula 6 · 04/09
Checkpoint 1
dados carregados, dicionário escrito, perfil de colunas pronto

aulas 8–9 · 18 e 25/09
Oficina do Trabalho 1
seções 1–4 escritas em sala · revisão cruzada · teste de reprodutibilidade

prazo · 30/09
Entrega 1 → Nota 1
seções 1 a 4 · 4–6 páginas no template SBC · pergunta, dados, entendimento, preparação

aulas 12 e 14
Checkpoints 2 e 3
15/10: EDA com respostas preliminares · 29/10: modelo rodando, com *baseline* e métrica

aulas 15–18 · novembro
Oficina do Trabalho Final
exploração → modelagem → escrita → reprodutibilidade: uma etapa por encontro

prazo · 30/11
Entrega 2 → Nota 2
relatório completo, seções 1 a 7 · 8–12 páginas · as quatro primeiras revisadas conforme o retorno da Entrega 1 · sem apresentação: o relatório fala pelo grupo

Como as duas notas se formam — pesos sugeridos, a confirmar no plano de ensino

Nota 1 — até 30/09

Entrega 1 do projeto — relatório SBC, seções 1–4	**70%**
Listas 1, 2 e 3 — aulas 2, 5 e 7	**30%**

Nota 2 — 01/10 a 30/11

Entrega 2 do projeto — relatório completo	**45%**
Prova prática — aula 11, com consulta	**35%**
Listas 4 e 5 — aulas 12 e 14	**20%**

Para onde foi o conteúdo das seis aulas que viraram oficina

Matplotlib — Figure/Axes, tipos de gráfico, escalas, subplots	→	**Aula 6** — agregou, plotou: o gráfico entra junto do `groupby`
Seaborn e comunicação — gráficos estatísticos, paletas, como um gráfico mente	→	**Aula 7** — distribuição, correlação e Anscombe já exigem o gráfico
Validação e vazamento — k-fold, vazamento de dados, `Pipeline` como defesa	→	**Aula 12** — é fundamento, não tópico avançado — entra com o primeiro modelo
***Tuning* e diagnóstico** — Grid/RandomizedSearchCV, curvas de aprendizado, features	→	**Aula 13** — ajustar o modelo logo depois de saber escolhê-lo
Não supervisionado — k-means, PCA, detecção de anomalias	→	**Aula 14** — fecha o panorama de modelos no mesmo encontro
Do notebook à realidade — serialização, MLOps, FastAPI, *drift*	→	**Aula 14** — "treinou, e agora?" — o fecho natural do bloco
Viés algorítmico, LGPD e limites epistêmicos — o que dado nenhum consegue afirmar	→	**Aula 10** — junto de scraping, robots.txt e termos de uso: é tudo a mesma conversa sobre a origem e o uso legítimo do dado

As aulas **6, 7, 12 e 14** ficam longas — a 14 em especial. Vale registrar isso no plano de ensino e chegar com o material fechado.