Análise de Atrasos e Cancelamentos de Voos nos Estados Unidos entre 2019 e 2023

Amanda de Moraes Dias, Priscila Nicoli Batista

Universidade Regional Integrada do Alto Uruguai e das Missões – URI
Curso de Ciência da Computação

amandamdias@aluno.santoangelo.uri.br

priscilanbatista@aluno.santoangelo.uri.br

Abstract. *Air transportation is subject to delays and cancellations that may be related to different flight characteristics and airport operations. This study uses the Flight Delay and Cancellation Data (2019–2023)_v2 dataset, composed of data from flights operated in the United States between 2019 and 2023. The objective is to investigate characteristics related to the occurrence of delays and cancellations, considering information such as period, time, airline, airports, and operational characteristics of flights. In this first stage, the dataset, its initial understanding, and the procedures adopted for data preparation are presented, establishing the basis for subsequent analysis and modeling.*

Resumo. *O transporte aéreo está sujeito a atrasos e cancelamentos que podem estar relacionados a diferentes características dos voos e das operações aeroportuárias. Este trabalho utiliza o conjunto de dados Flight Delay and Cancellation Data (2019–2023)_v2, composto por dados de voos realizados nos Estados Unidos entre 2019 e 2023. O objetivo é investigar características relacionadas à ocorrência de atrasos e cancelamentos, considerando informações como período, horário, companhia aérea, aeroportos e características operacionais dos voos. Nesta primeira etapa, são apresentados o conjunto de dados, seu entendimento inicial e os procedimentos adotados para sua preparação, estabelecendo a base para as etapas posteriores de análise e modelagem.*

1. Introdução

Atrasos e cancelamentos fazem parte dos problemas enfrentados no transporte aéreo e podem ocorrer em diferentes situações ao longo das operações de um voo. A disponibilidade de grandes conjuntos de dados sobre essas operações permite investigar esses acontecimentos e identificar características relacionadas à sua ocorrência.

Neste trabalho será utilizado o conjunto de dados *Flight Delay and Cancellation Data (2019–2023)_v2*, que reúne informações sobre voos realizados nos Estados Unidos entre os anos de 2019 e 2023. O conjunto contém informações relacionadas às companhias aéreas, aeroportos de origem e destino, horários, distância, atrasos, cancelamentos e outros aspectos das operações dos voos.

A partir desses dados, o trabalho busca responder às seguintes perguntas:
P1 — Quais características operacionais dos voos estão relacionadas à ocorrência de atrasos?
P2 — Como a frequência de atrasos varia de acordo com o período e o horário de realização dos voos?
P3 — Quais características dos voos estão relacionadas à ocorrência de cancelamentos?

2. Os Dados

Para a realização deste trabalho foi utilizado o conjunto de dados *Flight Delay and Cancellation Data (2019–2023)_v2*, disponibilizado publicamente na plataforma Kaggle [Zel 2023]. O conjunto reúne informações sobre voos realizados nos Estados Unidos, permitindo analisar diferentes aspectos relacionados às operações aéreas.

O arquivo utilizado neste trabalho é o flights_sample_2m.csv, composto por 2.000.000 de registros e 32 variáveis. Cada linha do conjunto de dados representa um voo, sendo essa a unidade de observação adotada no estudo. Os registros utilizados abrangem o período de 2019 a agosto de 2023.

Entre as informações disponíveis estão a data do voo, companhia aérea, aeroportos e cidades de origem e destino, horários programados e realizados, atrasos na partida e na chegada, distância percorrida, duração do voo, ocorrência de cancelamentos e variáveis relacionadas às causas dos atrasos.

O conjunto de dados foi obtido na plataforma Kaggle, por meio da página *Flight Delay and Cancellation Data (2019–2023)_v2*. Na plataforma, a licença do conjunto é apresentada como “Other (specified in description)”. Dessa forma, essa classificação é mantida neste trabalho, sem atribuir ao conjunto uma licença específica que não esteja explicitamente identificada na página utilizada para sua obtenção.

2.1. Dicionário das principais variáveis

O arquivo utilizado possui 32 variáveis. A Tabela 1 apresenta as principais variáveis consideradas para o entendimento e desenvolvimento deste estudo.

Tabela 1. Dicionário das principais variáveis utilizadas no estudo

Variável	Descrição
FL_DATE	Data de realização do voo
AIRLINE	Companhia aérea responsável pelo voo
ORIGIN	Aeroporto de origem
ORIGIN_CITY	Cidade de origem
DEST	Aeroporto de destino
DEST_CITY	Cidade de destino
CRS_DEP_TIME	Horário programado de partida
DEP_TIME	Horário real de partida

DEP_DELAY	Atraso na partida
ARR_DELAY	Atraso na chegada
CANCELLED	Indica se o voo foi cancelado
CANCELLATION_CODE	Código relacionado ao motivo do cancelamento
AIR_TIME	Tempo de voo
DISTANCE	Distância do voo
DELAY_DUE_CARRIER	Atraso relacionado à companhia aérea
DELAY_DUE_WEATHER	Atraso relacionado às condições meteorológicas
DELAY_DUE_NAS	Atraso relacionado ao sistema de aviação
DELAY_DUE_SECURITY	Atraso relacionado à segurança
DELAY_DUE_LATE_AIRCRAFT	Atraso relacionado à chegada tardia da aeronave

3. Entendimento dos Dados

Após o carregamento do arquivo flights_sample_2m.csv, foi realizada uma análise inicial para compreender sua estrutura e identificar possíveis problemas que deverão ser tratados antes das etapas posteriores.

O conjunto utilizado possui 2.000.000 de registros e 32 colunas, sendo cada registro correspondente a um voo. Os dados abrangem o período entre 2019 e 2023 e apresentam variáveis numéricas, categóricas, temporais e textuais.

Para realizar esse entendimento inicial, foram verificadas as dimensões do conjunto, os tipos das variáveis, a quantidade de valores distintos, a presença de valores ausentes e a existência de registros duplicados.

3.1 Tipos e diversidade dos dados

O conjunto apresenta diferentes tipos de informações. Entre as variáveis numéricas encontram-se distância, tempo de voo e medidas relacionadas aos atrasos. As variáveis categóricas incluem companhia aérea, aeroporto de origem, aeroporto de destino e situação de cancelamento. A variável FL_DATE representa a data do voo e permite trabalhar com a dimensão temporal do conjunto.

Também foi observada uma diversidade significativa nas variáveis categóricas. O conjunto possui 18 companhias aéreas diferentes, além de 380 aeroportos de origem e 380 aeroportos de destino.

Essa variedade permite realizar comparações entre diferentes companhias, aeroportos e períodos nas etapas posteriores do trabalho.

3.2 Valores ausentes

A análise inicial identificou valores ausentes principalmente em variáveis relacionadas aos atrasos e cancelamentos, conforme demonstrado na tabela 2.

Tabela 2. Valores ausentes

Variável	Valores ausentes
CANCELLATION_CODE	97,37%
DELAY_DUE_CARRIER	82,19%
DELAY_DUE_WEATHER	82,19%
DELAY_DUE_NAS	82,19%
DELAY_DUE_SECURITY	82,19%
DELAY_DUE_LATE_AIRCRAFT	82,19%
ARR_DELAY	2,86%
AIR_TIME	2,86%
DEP_DELAY	2,57%
DEP_TIME	2,57%

A presença desses valores não deve ser interpretada automaticamente como um erro. Algumas variáveis somente possuem informação quando determinado evento ocorre. Um exemplo é CANCELLATION_CODE, que apresenta o motivo do cancelamento e, portanto, não possui valor para a maioria dos voos que foram realizados normalmente.

No conjunto analisado foram identificados 52.522 voos cancelados, correspondendo a aproximadamente 2,63% dos 2 milhões de registros. Isso ajuda a explicar a grande quantidade de valores ausentes em CANCELLATION_CODE, pois essa informação é aplicável apenas aos voos cancelados. Da mesma forma, as variáveis DELAY_DUE_* precisam ser analisadas considerando que representam causas específicas de atraso e não necessariamente devem possuir valores para todos os voos.

3.3 Duplicidades

Também foi verificada a presença de registros completamente duplicados no conjunto de dados. A análise não identificou duplicações, resultando em:

Registros duplicados: 0

Dessa forma, não foi necessária a remoção de registros por duplicidade completa nesta etapa.

3.4 Problemas identificados

A análise inicial mostrou que o principal ponto que exige atenção está relacionado aos valores ausentes. Como algumas ausências possuem significado dentro do próprio contexto

dos dados, não é adequado simplesmente excluir todas as linhas que apresentam valores vazios.

Também será necessário adequar algumas variáveis ao formato utilizado nas análises. A data do voo, por exemplo, deverá ser tratada como uma variável temporal, permitindo posteriormente obter informações como ano, mês e dia da semana.
Esses aspectos serão considerados na etapa de preparação dos dados, na qual cada tratamento será realizado de acordo com o significado da variável e com os objetivos definidos para o trabalho.

Observação sobre os valores ausentes: um dos critérios estabelecidos para o projeto indica que o conjunto de dados deve possuir pelo menos uma variável com percentual de valores ausentes entre 5% e 50%. Durante a análise do conjunto selecionado, verificou-se que nenhuma das variáveis se encontra nessa faixa. As variáveis DEP_DELAY e DEP_TIME, por exemplo, apresentam aproximadamente 2,57% de valores ausentes, enquanto as variáveis relacionadas às causas de atraso (DELAY_DUE_*) apresentam aproximadamente 82,19%. Dessa forma, o conjunto não atende especificamente a esse critério. Optou-se por manter o dataset originalmente selecionado e informar essa limitação de forma explícita, sem realizar alterações artificiais nos dados apenas para atender ao percentual estabelecido.

4. Preparação dos Dados

Após o entendimento inicial do conjunto de dados, foi realizada a etapa de preparação com o objetivo de adequar as informações para as análises posteriores. Os tratamentos foram definidos considerando o significado de cada variável, evitando a remoção ou substituição automática de valores ausentes.

4.1 Tratamento da variável temporal

A variável FL_DATE, responsável por representar a data do voo, estava inicialmente armazenada como texto. Ela foi convertida para um formato de data adequado, permitindo trabalhar corretamente com as informações temporais presentes no conjunto.

A partir dessa variável, foram criadas três novas informações: ano, mês e dia da semana. Essas variáveis serão utilizadas posteriormente para investigar possíveis diferenças na ocorrência de atrasos entre diferentes períodos. Após a conversão, não foram identificados problemas que exigissem a remoção de registros relacionados à data.

4.2 Tratamento dos valores ausentes

Os valores ausentes foram analisados de acordo com o significado de cada variável. Optou-se por não remover automaticamente todos os registros incompletos, pois foi identificado que determinadas ausências fazem parte da própria estrutura dos dados.

A variável CANCELLATION_CODE, por exemplo, apresenta aproximadamente 97,37% de valores ausentes. Foram identificados 52.522 voos cancelados, sendo que todos possuem um código de cancelamento. Ao mesmo tempo, nenhum voo não cancelado apresenta esse código. Dessa forma, os valores ausentes dessa variável foram preservados, pois representam voos para os quais um código de cancelamento não se aplica.

As variáveis relacionadas às causas dos atrasos apresentam aproximadamente 82,19% de valores ausentes. Foram encontrados 356.220 registros com essas informações,

e o menor atraso de chegada observado nesse grupo foi de 15 minutos. Como também existem valores iguais a zero nessas variáveis, optou-se por preservar os valores ausentes em vez de substituí-los por zero, evitando atribuir o mesmo significado a situações diferentes.

Também foram analisadas as ausências nas variáveis operacionais. Em ARR_DELAY, AIR_TIME e ELAPSED_TIME, os 57.231 valores ausentes correspondem a 52.522 voos cancelados e 4.709 voos desviados. Os valores ausentes de DEP_TIME e DEP_DELAY também estão relacionados a voos cancelados. Em CRS_ELAPSED_TIME, foram encontrados apenas 17 valores ausentes, todos pertencentes a voos cancelados.

Diante dessas características, os valores ausentes relacionados a essas situações foram mantidos. A remoção desses registros poderia eliminar informações importantes, principalmente porque os cancelamentos fazem parte das questões investigadas neste trabalho.

4.3 Verificação de registros duplicados

Foi verificada a existência de registros completamente duplicados no conjunto de dados. Não foram encontrados registros duplicados e, portanto, não foi necessária nenhuma remoção por esse motivo.

4.4 Resultado da preparação

Após os procedimentos de preparação, o conjunto permaneceu com 2.000.000 de registros. A quantidade de variáveis passou de 32 para 35, devido à criação das variáveis ANO, MES e DIA_SEMANA.

Referências

ZEL, Patrick. *Flight Delay and Cancellation Data (2019–2023)_v2*. Kaggle, 2023. Disponível em: https://www.kaggle.com/datasets/patrickzel/flight-delay-and-cancellation-data-2019-2023-v2. Acesso em: 24 set. 2026.