UNIVERSIDADE REGIONAL INTEGRADA DO ALTO URUGUAI E DAS MISSÕES

Análise de Dados de Anúncios do Airbnb em San Francisco

Maicon Amélio, Maykom Mikael e Deivid Nunes Oliveira

Departamento de Ciências da Computação – Universidade Regional Integrada do Alto Uruguai e das Missões (URI) Santo Ângelo – RS - Brasil

maykommwochniscki@aluno.santoangelo.uri.br

maiconhamelio@aluno.santoangelo.uri.br

deividnoliveira@aluno.santoangelo.uri.br

Abstract. *This study presents the initial phase of a data analysis project using a Kaggle dataset of 8,111 San Francisco Airbnb listings. The objective is to formulate three business questions to investigate property characteristics, pricing, guest activity, and host reputation. This stage focuses on data preparation, including handling missing values, duplicates, and data types. Key preprocessing steps involved transforming monetary and temporal data, standardizing boolean variables, dropping sparse columns, and creating derived features. Ultimately, this comprehensive data cleaning prepares the dataset for subsequent exploration, visualization, and modeling.*

Keywords: Data Science; Airbnb; Data Analysis; San Francisco; Accommodation.

Resumo. *Este trabalho apresenta a primeira etapa de um projeto de análise de dados com um conjunto público de anúncios do Airbnb em San Francisco. O objetivo é formular três perguntas de negócio e preparar os dados para exploração, visualização e modelagem posteriores. O conjunto possui 8.111 registros e 106 colunas sobre imóveis, localização, preços, anfitriões, avaliações e disponibilidade. Foram verificadas tipagem, valores ausentes, duplicidades, variáveis temporais e valores distintos, além de conversões monetárias e de datas, padronização de booleanos, remoção de colunas sem informação ou muito esparsas e criação de variáveis derivadas. O conjunto resultante está preparado para as análises subsequentes.*

Palavras-chave: Ciência de Dados; Airbnb; Análise de Dados; San Francisco; Hospedagem.

1. Introdução

Plataformas de hospedagem como o Airbnb disponibilizam uma grande quantidade de informações sobre imóveis, preços, localização, características dos anúncios, anfitriões e avaliações. A análise dessas informações pode auxiliar na compreensão das características relacionadas aos preços dos anúncios e da atividade observada na plataforma. Este projeto utiliza um conjunto de dados público de anúncios do Airbnb em San Francisco.

O objetivo é realizar um processo de análise de dados desde o entendimento e preparação do conjunto até a exploração e modelagem que serão desenvolvidas nas etapas seguintes. A partir do conjunto de dados foram definidas três perguntas de negócio:

Pergunta 1: Quais características do anúncio, como bairro, tipo de acomodação, capacidade,

quartos, banheiros e comodidades, estão associadas a preços de diária mais altos em San Francisco na data de coleta dos dados, e como essas informações podem orientar a precificação de um novo anúncio?

Pergunta 2: Quais combinações de bairro e tipo de acomodação apresentam maior atividade de hóspedes, utilizando o volume e a frequência de avaliações como aproximação da demanda, e como isso pode orientar a escolha de localização e tipo de imóvel?

Pergunta 3: Entre anúncios comparáveis no mesmo bairro e tipo de acomodação, fatores de reputação e confiança do anfitrião, como Superhost, tempo na plataforma, identidade verificada e avaliações, estão associados a preços mais altos, e quais desses fatores podem sustentar uma estratégia de preço premium?

As perguntas foram definidas para direcionar a análise para possíveis decisões relacionadas à precificação, escolha de localização e características de um anúncio. Nesta primeira etapa são apresentados os dados utilizados, seu entendimento e os procedimentos realizados para preparar o conjunto para as análises posteriores. Os resultados exploratórios, gráficos e a modelagem serão desenvolvidos na segunda etapa do projeto.

2. Os Dados

O conjunto de dados utilizado neste projeto é o **San Francisco Airbnb Listings**, disponibilizado publicamente por meio da plataforma Kaggle. De acordo com a identificação utilizada no notebook do projeto, a página do dataset informa licença **CC0: Public Domain**.

Cada linha do conjunto de dados representa um **anúncio (listing) do Airbnb em San Francisco**. As colunas apresentam diferentes características relacionadas ao imóvel, anfitrião, localização, preço, disponibilidade e avaliações.

O arquivo utilizado no projeto contém:

Característica	Quantidade/Informação
Registros	8.111
Colunas	106
Duplicatas exatas	0
Período relacionado aos dados	2019
Unidade de observação	Um anúncio do Airbnb
Fonte	Kaggle
Dataset	San Francisco Airbnb Listings
Licença informada na página	CC0: Public Domain

O conjunto apresenta variáveis numéricas, categóricas, temporais e textuais. Entre as principais variáveis utilizadas ou consideradas para as perguntas de negócio estão **price, neighbourhood_cleansed, property_type, room_type, accommodates, bedrooms, bathrooms, amenities, number_of_reviews, reviews_per_month, host_is_superhost, host_identity_verified, host_since e last_scraped.**

A variável **price** possui papel importante no projeto, pois representa o preço da diária do anúncio e será utilizada como uma das principais variáveis de interesse. Além disso, o preço também poderá ser utilizado como variável-alvo para a etapa de modelagem prevista para a segunda etapa do projeto.

O dataset também possui informações textuais, como nome e descrição dos anúncios, além de informações sobre os anfitriões e características dos imóveis. Essa diversidade de variáveis permite analisar diferentes aspectos relacionados aos anúncios.

É importante destacar que os dados representam um recorte dos anúncios disponível na coleta realizada em outubro de 2019. Portanto, os resultados obtidos na análise representam as características observadas nesse conjunto de dados e nesse período, não devendo ser interpretados automaticamente como uma representação atual do mercado de hospedagem.

3. Entendimento dos Dados

O primeiro procedimento realizado foi verificar o tamanho, os tipos das variáveis, valores distintos, valores ausentes e duplicidades.

O dataset possui 8.111 linhas e 106 colunas. A verificação realizada no notebook encontrou 0 duplicatas exatas.

O conjunto possui 44 colunas numéricas originalmente. Também existem variáveis categóricas, como neighbourhood_cleansed, property_type, room_type, bed_type, host_response_time, cancellation_policy, host_is_superhost e instant_bookable.

A variável neighbourhood_cleansed possui 37 valores distintos, enquanto property_type possui 26 valores distintos. Essas variáveis poderão ser utilizadas para comparações entre diferentes regiões e tipos de propriedade.

A variável price é originalmente armazenada como texto contendo símbolos monetários. Para verificar sua utilização como variável numérica contínua, o notebook realiza uma conversão temporária, identificando 526 valores distintos.

Também foram identificados valores ausentes em diversas colunas. Entre as variáveis que possuem entre 5% e 50% de valores ausentes estão apresentadas na Tabela 2.

Tabela 2. Variáveis com valores ausentes entre 5% e 50%.

Variável	Percentual de Ausência	Variável	Percentual de Ausência
notes	38,32%	review_scores_location	20,40%
license	37,12%	review_scores_cleanliness	20,39%

access	35,89%	review_scores_accuracy	20,39%
interaction	32,35%	review_scores_rating	20,36%
transit	29,77%	last_review	19,79%
house_rules	26,83%	first_review	19,79%
host_about	25,04%	reviews_per_month	19,79%
neighborhood_overview	24,88%	space	13,98%
security_deposit	20,86%	host_response_rate	11,43%
review_scores_value	20,40%	host_response_time	11,43%
review_scores_checkin	20,40%	cleaning_fee	11,39%
review_scores_communication	20,38%	host_neighbourhood	6,47%

Esses valores demonstram que o conjunto apresenta dados incompletos e, portanto,necessita de preparação antes da realização das análises.

3.1 Variáveis temporais

Foram analisadas as variáveis last_scraped, host_since, calendar_last_scraped, first_review e last_review.

A variável last_scraped apresenta a data 14/10/2019, indicando a data de coleta dos registros.

A variável host_since apresenta registros desde 03/03/2008 até 11/10/2019.

A variável first_review apresenta registros entre 03/05/2009 e 13/10/2019, enquanto last_review possui registros entre 04/10/2010 e 13/10/2019.

Essas informações demonstram que o conjunto possui variáveis temporais com amplitude superior a 12 meses, atendendo ao requisito definido para o projeto.

3.2 Verificação dos requisitos do dataset

O notebook também verifica os requisitos mínimos definidos para a escolha do dataset.

O conjunto possui mais de 2.000 registros, mais de 10 colunas de conteúdo, mais de três variáveis numéricas, uma variável numérica contínua (price após conversão), pelo menos três variáveis categóricas, variáveis categóricas com mais de cinco valores, variáveis temporais, campos textuais, valores ausentes e uma variável que pode ser utilizada como alvo na etapa de modelagem. Dessa forma, o conjunto atende aos requisitos definidos para o projeto.

4. Preparação dos Dados

A preparação teve como objetivo transformar o conjunto de dados bruto em uma estrutura mais adequada para as análises posteriores, mantendo as informações relevantes para as três

perguntas de negócio.

Inicialmente, o conjunto original foi preservado por meio de uma cópia. Em seguida, foram realizadas verificações e transformações específicas.

4.1 Remoção de duplicidades

Foi realizada uma verificação de duplicidades exatas no conjunto de dados. Não foram encontradas linhas duplicadas. Portanto, nenhuma linha precisou ser removida nessa etapa.

4.2 Conversão de valores monetários

As variáveis relacionadas a valores monetários foram convertidas para formato numérico. No caso da variável **price**, os símbolos de moeda e separadores foram removidos para possibilitar a utilização dos valores em cálculos estatísticos.

Também foram verificadas outras variáveis monetárias, como **weekly_price, monthly_price, security_deposit, cleaning_fee e extra_people.**

Foi identificado **1 registro com preço menor ou igual a zero**. Como um preço de diária não positivo não representa um valor adequado para as análises propostas, esse valor foi convertido para ausente (**NaN**).

4.3 Conversão de datas

As variáveis temporais foram convertidas para o formato de data, permitindo operações matemáticas e criação de novas variáveis.

Entre as principais datas utilizadas estão:

- **last_scraped;**
- **host_since;**
- **calendar_last_scraped;**
- **first_review;**
- **last_review.**

Essa transformação permite, por exemplo, calcular o tempo aproximado de atuação do anfitrião na plataforma.

4.4 Padronização de variáveis booleanas

Variáveis que utilizavam valores como **t, f, true, false, yes** e **no** foram padronizadas para valores booleanos. Entre elas estão variáveis relacionadas ao Superhost, verificação de identidade, reserva instantânea, disponibilidade e outras características do anúncio.

Essa padronização facilita as comparações que serão realizadas posteriormente.

4.5 Remoção de colunas sem informação

Foram identificadas cinco colunas completamente vazias:

- **thumbnail_url;**
- **medium_url;**
- **xl_picture_url;**
- **host_acceptance_rate;**

- **neighbourhood_group_cleansed.**

Como essas colunas não possuem valores disponíveis para os registros, foram removidas do conjunto preparado.

Também foram removidas as colunas **square_feet, weekly_price e monthly_price**, pois apresentam mais de 80% de valores ausentes e não são necessárias para responder diretamente às perguntas de negócio definidas.

Além disso, foram retirados alguns campos técnicos relacionados a URLs e informações utilizadas principalmente para identificação técnica de coleta, como **listing_url, host_url, picture_url, host_thumbnail_url, host_picture_url e scrape_id.**

A remoção desses campos busca reduzir informações que não contribuem diretamente para as perguntas analisadas.

4.6 Criação de variáveis derivadas

Além da limpeza, foram criadas algumas variáveis para facilitar as análises futuras. A partir da coluna **amenities**, foi criada a variável **amenities_count**, representando a quantidade de comodidades informadas para cada anúncio.

Também foi criada a variável **price_per_guest**, calculada a partir do preço e da capacidade de hospedagem (**accommodates**). Essa variável poderá auxiliar na comparação entre anúncios com diferentes capacidades.

A variável **host_tenure_years** foi criada a partir das datas **last_scraped** e **host_since**, permitindo estimar o tempo de atuação do anfitrião na plataforma. Também foi criada **days_since_last_review**, calculando a quantidade de dias entre a última coleta e a última avaliação registrada. Outra variável criada foi **has_reviews**, indicando se o anúncio possui pelo menos uma avaliação.

Essas variáveis foram criadas com finalidade analítica e estão relacionadas diretamente às perguntas de negócio definidas para o projeto.

4.7 Tratamento de valores extremos

A variável **price** também foi analisada para identificar valores potencialmente extremos, após a conversão para formato numérico, o preço mediano observado foi de **150** dólares. Utilizando o método do intervalo interquartil (IQR), foi calculado um limite superior de aproximadamente **450** dólares.

Foram identificados **583** anúncios classificados como possíveis outliers pelo critério utilizado, esses registros não foram removidos nesta etapa. A decisão foi mantê-los e apenas sinalizá-los por meio da variável **price_outlier_iqr**, pois valores elevados podem representar anúncios legítimos com características diferenciadas.

Dessa forma, evita-se retirar antecipadamente informações que poderão ser importantes para a primeira pergunta de negócio, relacionada aos fatores associados a preços mais altos.

4.8 Resultado da preparação

Após a preparação, o conjunto manteve os **8.111 registros**, pois não havia duplicidades para serem removidas. Foram realizadas transformações nos tipos de dados, remoção de campos sem informação ou sem utilidade para as perguntas, tratamento de preços inválidos e criação de variáveis derivadas.

A preparação pode ser resumida da seguinte forma:

Etapa	Resultado
Linhas no dataset original	8.111
Colunas originais	106
Duplicatas removidas	0
Colunas 100% vazias removidas	5
Colunas com mais de 80% de ausência removidas	3
Campos técnicos removidos	6
Colunas após essas remoções	92
Preços menores ou iguais a zero tratados	1
Preço mediano	US$ 150
Limite superior do IQR	US$ 450
Outliers de preço sinalizados	583

O conjunto preparado foi salvo como **listings_clean.csv**, mantendo o dataset pronto para as análises estatísticas, visualizações e modelagem da segunda etapa.

Referências

KAGGLE. **San Francisco Airbnb Listings**. Dataset público utilizado no projeto. Licença informada na página: CC0: Public Domain. Acesso em: 24 set. 2026.

SOCIEDADE BRASILEIRA DE COMPUTAÇÃO (SBC). **Modelos para publicação de artigos**. Template utilizado para elaboração do relatório científico.