ANÁLISE DE ANÚNCIOS DO AIRBNB EM CHICAGO: PREÇOS, LOCALIZAÇÃO E CARACTERÍSTICAS DAS ACOMODAÇÕES

Helena Eduarda Oliveira Machado[1], Guilherme Cauã da Luz Machado[1]

[1]URI Campus de Santo Ângelo

helenaeomachado@aluno.santoangelo.uri.br,
guilhermecdlmachado@aluno.santoangelo.uri.br

Abstract. *This work presents the first stage of a data analysis regarding Airbnb listings in Chicago, Illinois, using a public dataset provided by the Inside Airbnb project. The objective is to structure an analysis driven by business questions concerning price, location, accommodation type, and listing characteristics. This stage covers the problem context, three business questions, a description of the data source and unit of observation, an understanding of the data structure, and the preparation process.*

Resumo. *Este trabalho apresenta a primeira etapa de uma análise de dados sobre anúncios de hospedagem do Airbnb em Chicago, Illinois, utilizando um conjunto público disponibilizado pelo projeto Inside Airbnb. O objetivo é estruturar uma análise orientada a questões de negócio relacionadas ao preço, à localização, ao tipo de acomodação e às características dos anúncios. Nesta etapa são apresentadas a contextualização do problema, as três perguntas de negócio, a descrição da fonte e da unidade de observação, o entendimento da estrutura dos dados e o processo de preparação.*

1. INTRODUÇÃO

1.1 Contextualização

Plataformas de hospedagem por curta duração, como o Airbnb, disponibilizam informações sobre acomodações, preços, localização, avaliações e disponibilidade. Esses dados podem ser utilizados para compreender características do mercado de hospedagem de uma determinada cidade.

Neste trabalho, é analisado um conjunto de dados de anúncios do Airbnb localizado na cidade de Chicago, Illinois, nos Estados Unidos. O objetivo é investigar como características dos anúncios estão relacionadas ao preço, à disponibilidade e ao perfil das acomodações.

A análise é organizada como um processo de Ciência de Dados, contemplando obtenção, entendimento, limpeza e preparação dos dados. Na segunda etapa do projeto, o conjunto preparado será utilizado para análises exploratórias, visualizações e modelagem, conforme a evolução das perguntas de negócio.

1.2 Problema de negócio

Para proprietários ou administradores de acomodações, informações sobre localização, tipo de quarto, preço, avaliações e disponibilidade podem auxiliar na compreensão do posicionamento de um anúncio no mercado. Assim, o problema deste trabalho consiste em organizar e analisar os dados de anúncios de Chicago de modo a identificar padrões que possam subsidiar decisões relacionadas ao posicionamento e às características das acomodações.

1.3 Perguntas de negócio

Pergunta 1 — Localização e preço. Como o preço médio das acomodações varia entre os diferentes bairros de Chicago e quais regiões apresentam maior concentração de anúncios?

A pergunta relaciona localização e preço e permite comparar diferenças entre os bairros.

Pergunta 2 — Tipo de acomodação. Como o tipo de acomodação está relacionado ao preço e à disponibilidade dos anúncios no Airbnb em Chicago?

Serão considerados Entire home/apt, Private room, Shared room e Hotel room.

Pergunta 3 — Características dos anúncios. Quais características dos anúncios estão associadas aos maiores preços no Airbnb de Chicago?

Entre as características disponíveis estão tipo de acomodação, bairro, número mínimo de noites, quantidade de avaliações, disponibilidade anual e localização geográfica. A pergunta também estabelece uma ligação com a modelagem da Etapa 2, utilizando o preço como possível variável-alvo.

2. OS DADOS

2.1 Fonte e licença

O dataset utilizado neste trabalho é o arquivo listings.csv, proveniente do projeto Inside Airbnb. A página oficial do projeto disponibiliza dados públicos de diversas cidades e apresenta, para Chicago, a referência de 24 de junho de 2026. O projeto informa que os dados são disponibilizados sob a licença Creative Commons Attribution 4.0 International (CC BY 4.0). O conjunto utilizado corresponde às listagens detalhadas/summary listings empregadas no projeto.

2.2 Unidade de observação

A unidade de observação é um anúncio de acomodação. Portanto, cada linha representa um anúncio do Airbnb em Chicago, identificado pela variável **id**.

2.3 Características do dataset

Características	**Resultado**
Linhas	6.397
Colunas	16
Anúncios	6.397
Bairros	77
Tipos de acomodação	4
Coluna de preço	Sim
Coluna temporal	“last_review”
Coluna textual	“name”
Valores ausentes	Sim

Tabela 1. Características gerais do conjunto de dados.

2.4 Dicionário das variáveis

Variável	**Tipo**	**Descrição**
“id”	Numérica	Identificador do anúncio
“name”	Texto	Nome/título do anúncio
“host_id”	Numérica	Identificador do anfitrião
“host_name”	Texto	Nome do anfitrião
“neighbourhood_group”	Categórica	Grupo de bairros
“neighbourhood”	Categórica	Bairro do anúncio
“latitude”	Numérica contínua	Latitude da localização
“longitude”	Numérica contínua	Longitude da localização
“room_type”	Categórica	Tipo de acomodação
“price”	Numérica	Preço do anúncio

“minimum_nights”	Numérica	Número mínimo de noites
“number_of_reviews”	Numérica	Quantidade de avaliações
“last_review”	Temporal	Data da última avaliação
“reviews_per_month”	Numérica	Média de avaliações por mês
“calculated_host_listings_count”	Numérica	Quantidade calculada de anúncios do anfitrião
“availability_365”	Numérica	Dias disponíveis em um período de 365 dias

Tabela 2. Dicionário das principais variáveis utilizadas na análise.

3. ENTENDIMENTO DOS DADOS

3.1 Tipos de variáveis

O conjunto possui variáveis numéricas, categóricas, textuais e temporais. Entre as numéricas estão latitude, longitude, price, minimum_nights, number_of_reviews, reviews_per_month e availability_365. As principais categóricas são neighbourhood, room_type e neighbourhood_group. As variáveis textuais incluem name e host_name. A variável last_review representa a data da avaliação mais recente.

No arquivo analisado, as datas de last_review variam de 18/08/2013 a 21/09/2020, fornecendo um intervalo temporal superior a doze meses e permitindo a utilização da variável em análises temporais posteriores.

3.2 Distribuição dos tipos de acomodação

Tipo de acomodação	Quantidade
Entire home/apt	4.401
Private room	1.833
Shared room	90
Hotel room	73
Total	6.397

Tabela 3. Distribuição dos anúncios por tipo de acomodação.

O tipo Entire home/apt apresenta a maior quantidade de registros, seguido por Private room. Shared room e Hotel room possuem participação muito menor no conjunto. Essa diferença

deve ser considerada nas comparações da Etapa 2, pois grupos com poucos registros podem apresentar maior instabilidade em estatísticas agregadas.

3.3 Distribuição dos bairros

A variável neighbourhood contém 77 bairros distintos. Essa variável é central para a primeira pergunta de negócio, pois permite comparar preços e concentração de anúncios entre regiões. Também poderá ser utilizada em visualizações geográficas.

3.4 Análise da variável preço

Estatística	Valor
Mínimo	US$ 0
1º quartil	US$ 64
Mediana	US$ 99
3º quartil	US$ 155
Média	US$ 153,02
Máximo	US$ 10.000

Tabela 4. Estatísticas descritivas da variável price.

A média de US$ 153,02 é superior à mediana de US$ 99, indicando influência de valores elevados na distribuição. O máximo de US$ 10.000 também evidencia a presença de valores extremos que deverão ser investigados antes de análises baseadas em médias ou modelos sensíveis a outliers.

Também foi identificado um registro com preço igual a US$ 0. Esse caso não será removido automaticamente: primeiro deverá ser investigado para verificar se representa uma situação válida ou um problema de registro. A decisão de tratamento será documentada na preparação final.

3.5 Valores ausentes

Variável	Ausentes	Percentual
“neighbourhood_group”	6.397	100%
“last_review”	1.132	17,70%
“reviews_per_month”	1.132	17,70%

Demais variáveis	0	0%

Tabela 5. Valores ausentes identificados no dataset.

O conjunto possui duas variáveis com proporção de ausência entre 5% e 50%: last_review e reviews_per_month, ambas com 1.132 valores ausentes, correspondentes a 17,70% dos registros. neighbourhood_group apresenta 100% de ausência.

3.6 Origem dos valores ausentes

A análise mostrou que os 1.132 anúncios sem avaliações, identificados por number_of_reviews = 0, coincidem com os registros sem last_review e sem reviews_per_month. Dessa forma, a ausência dessas informações possui interpretação compatível com a inexistência de histórico de avaliações para esses anúncios.

Esse comportamento reforça a necessidade de diferenciar valores ausentes de valores iguais a zero. Em particular, preencher automaticamente os campos ausentes ou excluir os registros poderia eliminar informação relevante sobre anúncios sem avaliações.

4. PREPARAÇÃO DOS DADOS

4.1 Remoção de coluna sem informação

A variável neighbourhood_group apresenta 100% de valores ausentes e, portanto, não fornece informação analítica para as perguntas propostas. A coluna será removida da cópia de trabalho do dataset.

```
dados = df.copy()
dados = dados.drop(columns=["neighbourhood_group"])
```

4.2 Conversão da variável temporal

A variável last_review será convertida para o tipo datetime. Os valores ausentes serão mantidos como NaT, pois representam anúncios sem avaliação registrada.

```
dados["last_review"] = pd.to_datetime(dados["last_review"], errors="coerce")
```

4.3 Tratamento das variáveis relacionadas a avaliações

Os 1.132 valores ausentes de reviews_per_month coincidem com anúncios que possuem number_of_reviews = 0. Portanto, esses registros não serão simplesmente excluídos. Para preservar a informação, será criada uma variável indicadora denominada sem_avaliacoes.

```
dados["sem_avaliacoes"] = (dados["number_of_reviews"] == 0).astype(int)
```

Nessa variável, o valor 1 indica ausência de avaliações e o valor 0 indica pelo menos uma avaliação. Para análises que dependam de uma variável numérica completa, qualquer imputação de reviews_per_month deverá ser justificada e realizada somente após avaliar o efeito da ausência de histórico.

4.4 Investigação do preço

A variável price é central para as três perguntas de negócio e, por isso, seus valores extremos serão investigados. O registro com price = 0 será identificado para verificar sua origem antes de decidir pelo tratamento.

```
dados[dados["price"] == 0]
```

Da mesma forma, o valor máximo de US$ 10.000 não será eliminado apenas por ser elevado. A identificação de outliers deverá considerar sua plausibilidade e seu impacto sobre as análises posteriores.

4.5 Verificação de duplicidades

O identificador id será utilizado para verificar duplicidades. A presença de registros repetidos deve ser confirmada antes de qualquer exclusão, evitando remover observações válidas de maneira arbitrária.

```
dados["id"].duplicated().sum()
```

4.6 Dataset preparado

Ao final da preparação, o conjunto deverá conter as correções de tipos, a remoção da coluna sem informação e a variável sem_avaliacoes, mantendo os registros sem avaliações. A preparação será executada no notebook do projeto, de forma que o processo possa ser reproduzido a partir do arquivo listings.csv.

5. Resultados preliminares

A etapa de entendimento permitiu identificar características relevantes para o prosseguimento da análise. O conjunto possui 6.397 anúncios distribuídos em 77 bairros e quatro tipos de acomodação. Entire home/apt concentra a maior quantidade de registros, enquanto Shared room e Hotel room possuem menor representação.

Em relação ao preço, a mediana de US$ 99 e a média de US$ 153,02, juntamente com o máximo de US$ 10.000, indicam uma distribuição que deve ser analisada com atenção a

valores extremos. Os resultados preliminares, entretanto, não respondem integralmente às perguntas de negócio, pois ainda é necessário comparar bairros, tipos de acomodação e características dos anúncios de forma conjunta.

Assim, os achados desta etapa funcionam principalmente como base para a exploração estatística e visual que será desenvolvida na Etapa 2.

6. Limitações e cuidados analíticos

O conjunto apresenta limitações que devem ser consideradas na interpretação dos resultados. A primeira é a presença de valores ausentes em variáveis relacionadas às avaliações. Esses valores não devem ser tratados automaticamente como erros, pois estão associados a anúncios sem avaliações. A segunda é a existência de valores extremos na variável price, que pode afetar médias e modelos estatísticos. Também existe uma coluna completamente ausente, removida por não fornecer informação.

Outra limitação é que a variável last_review registra a data da última avaliação, e não necessariamente a data de criação ou de disponibilização do anúncio. Portanto, análises temporais baseadas nessa variável devem deixar claro o que a data representa.

7. Considerações Finais

A primeira etapa do projeto estruturou o problema de negócio e preparou o dataset de anúncios do Airbnb em Chicago para análises posteriores. Foram definidas três perguntas relacionadas à localização e preço, ao tipo de acomodação e às características associadas ao preço.

O entendimento dos dados identificou 6.397 registros, 16 variáveis, 77 bairros, quatro tipos de acomodação e padrões de ausência relevantes. A preparação foi definida de maneira a preservar informações úteis, especialmente os anúncios sem avaliações, e a evitar exclusões automáticas de valores potencialmente válidos ou extremos.

Com o dataset preparado e o processo documentado no notebook, a próxima etapa poderá avançar para visualizações, análises estatísticas e modelagem, buscando responder de forma quantitativa às três perguntas de negócio.

Referências

[1] INSIDE AIRBNB. Get the Data. Dados públicos de anúncios de hospedagem, incluindo Chicago. 2026. Disponível em: https://insideairbnb.com/get-the-data/. Acesso em: 25 set. 2026.

[2] INSIDE AIRBNB. Data Policies. Políticas e informações sobre os dados disponibilizados pelo projeto. 2026. Disponível em: https://insideairbnb.com/data-policies/. Acesso em: 25 set. 2026.