Panorama da Infraestrutura Cinematográfica no Brasil: Uma Análise do Parque Exibidor a Partir dos Dados Abertos da ANCINE

Camila dos Santos[1], Flávia Figueiró[1], Isabela Cadore[1]

[1]Curso de Bacharelado em Ciência da Computação Universidade Regional Integrada do Alto Uruguai e das Missões (URI) Santo Ângelo, RS – Brasil

camilasdsantos@aluno.santoangelo.uri.br,
flaviasfigueiro@aluno.santoangelo.uri.br,
isabelascadore@aluno.santoangelo.uri.br

Abstract. *This paper presents an exploratory analysis of the Brazilian cinematographic infrastructure based on the Exhibition Rooms dataset from ANCINE's Open Data Portal. Using a Data Science pipeline, the study maps the geographical distribution of theaters, measures physical accessibility levels for people with disabilities, and analyzes market concentration among economic groups. The results diagnose regional asymmetries and inclusive compliance, providing empirical insights for public policy evaluation in the national audiovisual sector.*

Resumo. *Este artigo apresenta uma análise exploratória sobre a infraestrutura cinematográfica brasileira a partir do dataset de Salas de Exibição do Portal de Dados Abertos da ANCINE. Utilizando um pipeline de Ciência de Dados, o estudo mapeia a distribuição geográfica do parque exibidor, mensura o nível de acessibilidade física para pessoas com deficiência e analisa a concentração de mercado entre os grupos econômicos. Os resultados diagnosticam as assimetrias regionais e a adequação inclusiva das salas, fornecendo subsídios empíricos para a avaliação de políticas públicas no setor audiovisual nacional.*

1. Introdução

A Agência Nacional do Cinema (ANCINE) é a autarquia federal em regime especial responsável por formular, implementar e fiscalizar as políticas públicas voltadas ao setor audiovisual no Brasil. Criada pelo artigo 5º da Medida Provisória nº 2228-1, a entidade possui autonomia administrativa e financeira, atuando vinculada ao Ministério da Cultura com o propósito de fomentar a produção, a distribuição e a exibição de obras cinematográficas e videofônicas nacionais, promovendo o desenvolvimento da infraestrutura cultural no país. Nesse contexto, a transparência pública e a disponibilização de dados abertos viabilizam a investigação contínua e analítica do mercado audiovisual.

Para viabilizar este estudo, utiliza-se o conjunto de dados de Salas de Exibição, disponibilizado no Portal de Dados Abertos da ANCINE (ANCINE, 2026). Essa base, reúne registros detalhados sobre a infraestrutura do cinema brasileiro, abrangendo variáveis de identificação regulatória, como nome da sala e do complexo, números de

registro, CNPJ, situação cadastral e data de início de funcionamento, além de mapear os atores econômicos envolvidos por meio do registro das empresas exibidoras e dos grupos exibidores responsáveis. Adicionalmente, o dataset contempla a localização geográfica completa dos complexos, englobando endereço, bairro, município, CEP e Unidade Federativa (UF), bem como a distinção de estruturas itinerantes e o tipo de operação usual.

Outro aspecto fundamental, presente na base, diz respeito à infraestrutura física e à acessibilidade inclusiva. Desse modo, o acervo apresenta informações sobre a capacidade total de assentos das salas e a quantidade de espaços reservados para cadeirantes, pessoas com mobilidade reduzida e pessoas com obesidade, além de indicar a presença de rampas de acesso e banheiros adaptados. A partir desse conjunto de variáveis, o presente trabalho aplica um pipeline de Ciência de Dados estruturado para responder a três perguntas centrais que norteiam a investigação:

Primeiramente, o Índice de Acessibilidade e Inclusão por Grupo Exibidor e Região: Qual grupo exibidor ou Unidade Federativa (UF) possui o maior percentual de salas plenamente acessíveis (cruzando assentos para cadeirantes, mobilidade reduzida e obesidade, rampas de acesso e banheiros acessíveis), e onde se concentram os maiores gargalos de conformidade e infraestrutura Em seguida, a Distribuição Territorial e Oportunidades de Expansão: Como estão distribuídos os assentos por município e qual é a participação dos complexos itinerantes versus permanentes no atendimento a praças fora dos grandes centros urbanos, evidenciando potenciais "desertos culturais"?

Por fim, a Concentração de Mercado e Dinâmica de Sobrevivência Operacional: Qual é a taxa de inativação/manutenção de salas e complexos ao longo do tempo (com base na situação cadastral e data de início de funcionamento), e como a estabilidade operacional se divide entre grandes grupos exibidores e exibidores independentes? Dessa forma, a pesquisa busca fornecer um diagnóstico empírico fundamentado sobre a acessibilidade física, a equidade territorial e a estrutura competitiva do parque exibidor no país.

2. Estrutura e Caracterização dos Dados

Para dar suporte analítico às hipóteses formuladas, faz-se necessário detalhar a origem, a conformidade jurídica, a unidade analítica e a organização das variáveis que compõem o corpus de dados deste estudo.

2.1. Fonte dos Dados e Licenciamento

O conjunto de dados utilizado provém do Portal de Dados Abertos da Agência Nacional do Cinema (ANCINE), sob o repositório institucional mantido pelo Governo Federal. Por se tratar de uma base pública governamental, o acervo está submetido aos preceitos da Lei de Acesso à Informação (Lei nº 12.527/2011) e disponibilizado sob licença aberta (Open Data), permitindo o livre manuseio, o processamento computacional e a reutilização para fins de pesquisa científica e transparência pública.

2.2. Unidade de Observação

A unidade de observação é a sala de exibição cinematográfica individual. Isso significa que cada linha presente na base de dados corresponde a uma única sala de cinema cadastrada na ANCINE, identificada unicamente pelo seu registro regulatório *(REGISTRO_SALA)*. Consequentemente, dados agregados, como complexos de cinemas, grupos exibidores ou municípios, são representados de forma recorrente ao longo do dataset, dependendo do quantitativo de salas vinculadas a cada estrutura superior.

2.3. Dicionário de Dados e Categorização das Variáveis

Com o intuito de viabilizar o processamento técnico no *pipeline* de Ciência de Dados, as 32 variáveis originais do acervo foram organizadas e classificadas em quatro dimensões analíticas principais. A tipagem indicada a seguir refere-se ao modelo conceitual requerido para as análises:

Dimensão Analítica	**Nome da Variável**	**Tipo de Dado**	**Descrição/Função Regulatória**
Identificação da Sala	*NOME_SALA* *REGISTRO_SALA* *CNPJ_SALA* *SITUACAO_SALA*	Categórico / ID	Nome fantasia, identificadores regulatórios da sala e situação operacional (ex.: Ativa, Inativa).
Histórico Temporal	*DATA_SITUACAO_SALA* *DATA_INICIO_FUNCIONAMENTO_SALA* *DATA_SITUACAO_COMPLEXO*	Data (datetime)	Marcos temporais de alteração cadastral e início de operação comercial do estabelecimento.
Capacidade e Vagas Adaptadas	*ASSENTOS_SALA* *ASSENTOS_CADEIRANTES* *ASSENTOS_MOBILIDADE_REDUZIDA* *ASSENTOS_OBESIDADE*	Numérico Inteiro (int64)	Capacidade máxima de público e quantitativo de vagas reservadas para pessoas com deficiência (PcD).

Acessibilidade Estrutural	*ACESSO_ASSENTOS_COM_RAMPA* *ACESSO_SALA_COM_RAMPA* *BANHEIROS_ACESSIVEIS*	Binário (0 ou 1)	Indicadores de presença de rampas nos acessos/assentos e disponibilidade de sanitários adaptados.
Geolocalização e Operação	*NOME_COMPLEXO* *REGISTRO_COMPLEXO* *BAIRRO_COMPLEXO* *MUNICIPIO_COMPLEXO* *UF_COMPLEXO* *COMPLEXO_ITINERANTE* *OPERACAO_USUAL*	Categórico / Geográfico	Dados do complexo, localização física, indicador de mobilidade (Fixa vs. Itinerante) e regime de funcionamento.
Agentes Econômicos	*NOME_EXIBIDOR* *REGISTRO_EXIBIDOR* *CNPJ_EXIBIDOR* *NOME_GRUPO_EXIBIDOR*	Categórico / ID	Razão social do operador imediato, situação cadastral do exibidor e grupo econômico mantenedor.

3. Entendimento e Qualidade dos Dados

Nesta etapa do trabalho, realizou-se um diagnóstico quantitativo e qualitativo da integridade do dataset de Salas de Exibição da ANCINE. Com o objetivo de mapear a estrutura física do arquivo, compreender o comportamento de suas variáveis e identificar inconsistências ou defeitos de preenchimento que exigirão intervenções na etapa de preparação de dados.

3.1. Dimensões do Arquivo e Tipagem de Dados

O acervo analisado faz-se composto por um volume total de 6.405 registros distribuídos em 32 atributos. Desse modo, a avaliação preliminar das variáveis revelou disparidades significativas entre os tipos de dados nativos armazenados no arquivo bruto e a real natureza conceitual das informações representadas.

No que tange aos identificadores e chaves primárias, constatou-se que o atributo *REGISTRO_SALA* foi importado como número de ponto flutuante (float64), o que induz à exibição indevida de casas decimais. Do mesmo modo, os campos *REGISTRO_COMPLEXO* e *REGISTRO_EXIBIDOR* foram carregados como inteiros (int64). Por não possuírem valor escalar ou propriedade aritmética, essas variáveis devem ser tratadas estritamente como cadeias de caracteres (strings) categóricas de identificação.

Em relação aos dados temporais, variáveis críticas como *DATA_SITUACAO_SALA, DATA_INICIO_FUNCIONAMENTO_SALA* e *DATA_SITUACAO_COMPLEXO* encontram-se formatadas genericamente como texto (str). Essa ausência de padronização, impede a execução direta de operações cronológicas e o cálculo do ciclo de vida dos estabelecimentos, demandando a conversão prévia para o tipo nativo datetime.

3.2. Cardinalidade e Valores Distintos

A análise de cardinalidade permite mensurar a dispersão informacional e a variabilidade dos atributos dentro do parque exibidor nacional. No âmbito da infraestrutura física, constatam-se 6.368 registros distintos de salas vinculados a 2.014 complexos cinematográficos, evidenciando uma densidade média nacional de aproximadamente 3 salas por estabelecimento. Sob a perspectiva espacial e corporativa, o ecossistema mapeado engloba 607 municípios distribuídos por todas as 27 Unidades Federativas do país. No contexto empresarial, os dados apontam a presença de 873 empresas exibidoras estruturadas sob a gestão de 75 grupos exibidores de atuação regional ou nacional.

Por sua vez, os atributos qualitativos referentes à acessibilidade física, tais como ACESSO_ASSENTOS_COM_RAMPA, ACESSO_SALA_COM_RAMPA e BANHEIROS_ACESSIVEIS, assim como o indicador de COMPLEXO_ITINERANTE, apresentam exatamente dois valores distintos representados pelas categorias "SIM" e "NÃO", o que atesta a padronização adequada no preenchimento desses campos.

3.3. Diagnóstico de Ausência de Dados e Defeitos Identificados

O levantamento dos percentuais de vacância (missing values) revelou fragilidades estruturais na qualidade do acervo público. Assim, a limitação mais expressiva reside no atributo DATA_INICIO_FUNCIONAMENTO_SALA, que exibe uma taxa de omissão de 85,87%. Essa vacância em massa, inviabiliza a reconstrução histórica completa da data exata de inauguração para a maior parte do parque exibidor nacional.

Embora os atributos qualitativos de rampas e sanitários estejam totalmente preenchidos, o detalhamento quantitativo da capacidade de assentos adaptados apresenta subnotificação expressiva. Tendo em vista que constatou-se que 30,71% das observações omitem a quantidade de ASSENTOS_MOBILIDADE_REDUZIDA,

28,63% não registram os ASSENTOS_OBESIDADE e 19,41% omitem a contagem de ASSENTOS_CADEIRANTES.

Adicionalmente, verificou-se a presença de um padrão sistemático de omissão: atributos fundamentais como NOME_SALA, REGISTRO_SALA, DATA_SITUACAO_SALA e ASSENTOS_SALA exibem exatamente 0,58% de valores nulos, enquanto os dados de localização física (ENDERECO_COMPLEXO, MUNICIPIO_COMPLEXO e UF_COMPLEXO) possuem 0,39% de ausência. Essa coincidência percentual estrita, indica a existência de registros órfãos ou corrompidos no arquivo original.

Por fim, os campos cadastrais secundários PAGINA_ELETRONICA_COMPLEXO e COMPLEMENTO_COMPLEXO apresentam taxas de vacância de 32,35% e 23,39%, respectivamente. Diante dessas constatações, estabelece-se a necessidade de aplicar estratégias de saneamento, eliminação de registros inconsistentes e imputação conservadora na etapa subsequente de tratamento de dados.

4. Preparação e Tratamento dos Dados

A etapa de preparação dos dados compreende o conjunto de transformações estruturais, sanitização sanitária e derivações de atributos aplicados sobre o acervo bruto disponibilizado pela Agência Nacional do Cinema (ANCINE). Essa fase, revela-se fundamental para eliminar ruídos operacionais, corrigir imperfeições de preenchimento, padronizar a tipagem computacional e estruturar a matriz analítica que fundamentará as respostas às três perguntas de pesquisa formuladas.

4.1. Limpeza e Tratamento de Inconsistências

Inicialmente, efetuou-se a limpeza sanitária da base para assegurar a integridade amostral e a robustez das inferências estatísticas. Nesse sentido, identificou-se um grupo residual de 37 registros que apresentavam ausência simultânea de dados em atributos essenciais de identificação e geolocalização. Por representarem uma fração insignificante da amostragem, inferior a 0,6% do total, optou-se pela remoção sumária dessas linhas corrompidas, ajustando o corpus analítico de 6.405 para 6.368 salas válidas.

Paralelamente, promoveu-se o descarte seletivo de colunas cadastrais secundárias que ostentavam elevadas taxas de omissão, a exemplo da página eletrônica, do complemento e do número do endereço do complexo. Essa eliminação de atributos irrelevantes, permitiu otimizar o desempenho computacional do pipeline e reduzir a redundância informacional, concentrando o estudo estritamente nas variáveis aderentes aos objetivos de negócio.

4.2. Harmonização de Tipos Primitivos e Vetorização

Na sequência, procedeu-se à harmonização dos tipos primitivos e à conversão dos formatos temporal tendo em vista que identificadores numéricos e códigos regulatórios não possuem valor escalar ou aritmético, as chaves primárias relativas aos registros das salas, complexos e exibidores foram convertidas do tipo numérico para caractere,

utilizando-se expressões regulares para suprimir sufixos decimais indevidos. Por sua vez, as variáveis cronológicas foram transformadas para o formato nativo de data, respeitando a ordenação do calendário brasileiro, condição técnica indispensável para viabilizar o cálculo exato de séries temporais e ciclos de permanência no mercado.

Adicionalmente, as variáveis qualitativas referentes à presença de rampas, banheiros adaptados e caráter itinerante do complexo foram remapeadas de texto para vetores binários. Quanto aos dados contínuos de assentos para pessoas com deficiência (PcD), aplicou-se a imputação conservadora por zero nas observações omissas, pautando-se na premissa regulatória de que a ausência de declaração formal no cadastro implica a inexistência do recurso físico na dependência avaliada.

4.3. Injeção de Dados Estocásticos e Engenharia de Recursos

Com vistas a expandir a capacidade explicativa da base e suprir lacunas informacionais, o acervo foi enriquecido por meio da engenharia de recursos. Em conformidade com as diretrizes metodológicas e por orientação expressa do docente, injetou-se a variável contínua estocástica de preço médio do ingresso simulado. Gerada mediante um processo estocástico reprodutível compreendido na faixa de R$ 18,00 a R$ 45,00, essa métrica visa subsidiar simulações financeiras no parque exibidor, compensando a indisponibilidade desses dados no portal público.

Por fim, visando responder diretamente às questões de pesquisa, construíram-se variáveis compostas e categóricas. Sendo assim, formulou-se o índice de acessibilidade da sala, uma métrica aditiva em escala de 0 a 6 que mensura a convergência de seis critérios de inclusão a partir do qual se derivou a flag binária indicativa de sala totalmente acessível. Sob a perspectiva de mercado, calculou-se o tempo de operação em anos a partir do histórico de funcionamento e quantificou-se o número total de salas por complexo, permitindo categorizar os estabelecimentos quanto ao porte operacional em estruturas single screen, multiplex e megaplex. Assim, após a aplicação integral destas rotinas, consolidou-se uma matriz de dados perfeitamente higienizada, composta por 6.368 observações e 37 atributos aptos para a modelagem estatística.

5. Exploração

6. Modelagem

7. Conclusão e limitações

8. References

ANCINE (2026) “Salas de Exibição”, Portal de Dados Abertos da Agência Nacional do Cinema, https://dados.gov.br/dados/conjuntos-dados/salas-de-exibicao-e-complexos-registrados-na-ancine