Inspeção de demanda de reservações de hotéis

Bernardo S. Novaczinski[1], Rodrigo L. Cibulski[1]

[1]Ciência da Computação – Universidade Regional Integrada do Alto Uruguai e das Missões (URI) – Santo Ângelo – RS – Brazil

bernardosnovaczinski@aluno.santoangelo.uri.br, rodrigolcibulski@aluno.santoangelo.uri.br

Abstract. *This paper outlines the processing of the Hotel Booking Demand dataset, which contains 119,390 reservations from a city hotel and a resort hotel from July 2015 to August 2017. We address three business questions: which booking characteristics indicate a higher probability of cancellation and how early the hotel can act for retention or conscious overbooking; how ADR and length of stay vary across months and hotel types; and which distribution channel and deposit type yield lower cancellation and higher added value.*

Resumo. *Este trabalho apresenta o tratamento do dataset Hotel Booking Demand, composto por 119.390 reservas de um hotel urbano e um hotel turístico, entre julho de 2015 e agosto de 2017. Buscamos responder três questões de negócio: identificar características da reserva associadas ao cancelamento e a antecedência para ações de retenção ou overbooking consciente; analisar a variação da diária média (ADR) e da duração da estadia por mês e tipo de hotel; e avaliar canal de distribuição e tipo de depósito com menor cancelamento e maior valor agregado.*

1. Introdução

O dataset selecionado foi o “Hotel Booking Demand”, baseado no artigo de mesmo nome que lista um conjunto de dados de reserva de um hotel urbano e um hotel turístico.

Escolhemos as três seguintes perguntas de negócio:

Quais características da reserva indicam maior probabilidade de cancelamento antes do check-in, e com qual antecedência o hotel consegue agir para aplicar estratégias de retenção ou overbooking consciente?

Como a taxa média diária e a duração da estadia variam ao longo dos meses do ano e entre os tipos de hotéis, e qual combinação gera maior receita líquida confirmada?

Qual canal de distribuição e tipo de depósito trazem reservas com menor taxa de cancelamento e maior valor agregado para o hotel?

2. Os Dados

A base reúne dados reais de reservas de dois meios de hospedagem, sendo um hotel urbano e um hotel turístico que foram coletados entre 1º de julho de 2015 a 31 de agosto de 2017. Os dados são disponibilizados publicamente sob a licença Creative Commons Attribution 4.0 International, que permite o uso, compartilhamento e adaptação livre dos dados para fins acadêmicos e analíticos.

As linhas do dataset representam uma reserva individual efetuada em um dos hoteis. Cada registro reflete o histórico, as características da estadia, as preferências

registradas e o status final dessa reserva.

2.1. Dicionário de Dados

O dataset possui 119390 linhas e 32 colunas, contendo as seguintes variáveis relevantes:

Tabela 1: Principais variáveis identificadas no dataset

	Tipo de Dado	Descrição das Variáveis
hotel	Categórica	Qual hotel foi escolhido.
is_canceled	Numérico (Binária)	Indica se a reserva foi cancelada (1) ou não (0).
lead_time	Numérico (Contínuo)	Número de dias entre a data da reserva e o check-in.
arrival_date_year, arrival_date_month	Temporal	Ano e mês previstos para a chegada do hóspede.
stays_in_weekend_nights, stays_in_week_nights	Numérico	Quantidade de diárias em fins de semana e dias úteis, respectivamente.
adults, children, babies	Numérico	Quantidade de adultos, crianças e bebês incluídos na reserva.
country	Texto	Nome do país de origem do hóspede por extenso.
market_segment, distribution_channel	Categóricas	Segmento de mercado e canal utilizado para efetuar a reserva.
deposit_type	Categórica	Tipo de depósito exigido na reserva.
agent, company	Numérico	ID da agência de viagens ou empresa responsável pela reserva.
adr	Numérico Contínuo	Taxa Média Diária.
reservation_status_date	Temporal	Data em que o último status da reserva foi registrado.

3. Entendimento

3.1. Tipos de Dados

As 32 variáveis estão divididas nos seguintes tipos:

- Contém 16 colunas do tipo int64 (*is_canceled*).
- Contém 12 colunas do tipo str (*hotel*).
- Contém 4 colunas do tipo float64 (*adr*).

3.2. Quantidade de dados ausentes:

- *company*: 94.31% dos valores ausentes.(112,593 registros nulos).
- *agent*: 13.69% dos valores ausentes.(16,340 registros nulos).
- *country*: 0.41% dos valores ausentes (488 registros nulos).

- *children*: 0.00% dos valores ausentes (4 registros nulos)

3.3. Diversidade e Valores Distintos

- **Poucos valores distintos (Variáveis Categóricas e Binárias):** *hotel* tem 2 tipos e *is_repeated_guest* tem 3 tipos.
- **Média amplitude (Categorias estruturadas):** *children* tem 5 valores distintos, *market_segment* tem 8 valores distintos e *reserved_room_type* tem 10 valores distintos.
- **Alta cardinalidade:** *country* tem 177 valores distintos e *lead_time* tem 479 valores distintos.

3.4. Defeitos Identificados no Dataset:

A variável *company* está composta por 94% de dados vazios, o que inviabiliza o uso para o cruzamento de dados e modelagem sem viés.

As categorias da variável *country* foram escritas usando a norma ISO 3155–3:2013, sendo necessário a conversão para nomes por extenso para atender à exigência de dados textuais e facilitar a legibilidade.

Foi identificado registros onde a soma de adultos, crianças e bebês resultava em zero, o que pode ser um erro de digitação ou reserva faltando.

Além disso, foi encontrado preços que vão de quantias negativas até valores fora do padrão da distribuição.

4. Preparação

A coluna *country* foi convertida do código ISO 3155–3:2013 para os nomes de países por extenso. Essa padronização atende aos requisitos do projeto e melhora a interpretabilidade dos dados, facilitando a leitura direta de tabelas e a construção de gráficos analíticos.

A variável *children* teve seus 4 valores ausentes substituídos por zero, indicando ausência de crianças na reserva e seu tipo de dado foi ajustado de *float64* para *int64,* alinhando a representação da coluna com as colunas *adults* e *babies*.

Os valores nulos das colunas *agent* e *company* foram substituídos por zero, indicando a ausência de intermediação por agências de viagens ou empresas parceiras na reserva.

Devido a ao baixo número de valores ausentes na coluna *country*, optou-se por substituí-los pelo rótulo *Unknown,* para evitar a eliminação indevida de dados válidos contidos nas demais.

Foram eliminados os registros com soma zero de hóspedes, assegurando assim a integridade da base de dados ao eliminar erros de integração de sistemas ou reservas de teste, visto que uma transação de hospedagem sem passageiros é inválida.

Na coluna *adr*, foram removidos o valor negativo 6.38 e o 5.400,00, por constituírem erros pontuais de digitação e representarem apenas uma ocorrência de cada

no dataset.

Referências

Mostipak, J. (2019) “Hotel booking demand”, https://www.kaggle.com/datasets/jessemostipak/hotel-booking-demand, Acesso em: Setembro 2026.