Projeto de Ciência de Dados

Gustavo Santos, Leonardo Pavão, Kaue da Rosa

Ciência da Computação – Universidade Regional Integrada do Alto Uruguai e das Missões (URI)
– 98.802-470 – Santo Ângelo – RS – Brazil

Matéria Ciência de Dados Universidade Regional Integrada do Alto Uruguai e das Missões (URI)- Santo Ângelo, RS – Brazil

gustavosilva36500@aluno.santoangelo.uri.br
leonardohpavao@aluno.santoangelo.uri.br
kauesilva@aluno.santoangelo.uri.br

Abstract. *This meta-paper describes the style to be used in articles and short papers for SBC conferences. For papers in English, you should add just an abstract while for the papers in Portuguese, we also ask for an abstract in Portuguese ("resumo"). In both cases, abstracts should not have more than 10 lines and must be in the first page of the paper.*

Resumo. *Este meta-artigo descreve o estilo a ser usado na confecção de artigos e resumos de artigos para publicação nos anais das conferências organizadas pela SBC. É solicitada a escrita de resumo e abstract apenas para os artigos escritos em português. Artigos em inglês deverão apresentar apenas abstract. Nos dois casos, o autor deve tomar cuidado para que o resumo (e o abstract) não ultrapassem 10 linhas cada, sendo que ambos devem estar na primeira página do artigo.*

1. Introdução

Este projeto visa o desenvolvimento de uma análise de negócio utilizando dados para responder algumas perguntas de negócio. Com o uso de ferramentas como VScode, linguagem Python, duas bibliotecas de busca e visualização de dados e Kaggle para retirar datasets.

O dataset escolhido foi o "Hotel Bookings" um dataset que armazena armazena as informações de reserva no sistema de gerenciamento de propriedades (PMS) de um hotel resort e de um hotel urbano. Os hotéis estão localizados na região turística do Algarve e na cidade de Lisboa, em Portugal.

Em cima desse dataset decidimos elaborar três perguntas:

1. Quais características de uma reserva permitem identificar, com antecedência, quais reservas apresentam maior risco de cancelamento, para que o hotel possa agir antes da data de chegada?

2. Quais segmentos concentram o maior valor financeiro associado a reservas canceladas e, portanto, deveriam ser priorizados em estratégias de redução de perdas?

3. Com quantos dias de antecedência o hotel normalmente fica sabendo de um cancelamento, e essa janela é suficiente para tentar vender novamente o quarto?

As perguntas têm o caráter de responder questões de negócio envolvendo as informações armazenadas no sistema de gerenciamento de propriedades. Pois tais questões refletem sobre o cancelamento de reservas.

É de vital importância responder essas questões pois elas atingem o negócio de hotelaria com total impacto. Para a garantia de expansão e melhoria contínua dos serviços prestados, é extremamente necessário entender onde, porquê e quando vão ocorrer os cancelamentos. Essa atitude ajuda não só o momento atual do hotel (que utilizará esses dados para gerir o seu negócio) mas, também ajuda o futuro do hotel (que utiliza essas informações para gerar análises e assim, poder melhorar e aumentar a qualidade do hotel como um todo)

2 - Dados

Fonte

O nosso dataset é denominado “Hotel Bookings”. Ele foi publicado pelo usuário “mexwell” dentro da plataforma Kaggle. O dataset pode ser acessado pelo link: (https://www.kaggle.com/datasets/mexwell/hotel-bookings).

Os dados originais foram retirados de um sistema de gerenciamento de propriedades (PMS) de um hotel resort e de um hotel urbano, localizados na região turística do Algarve e na cidade de Lisboa, em Portugal. Os dados originais podem ser encontrados no link:
(https://www.sciencedirect.com/science/article/pii/S2352340918315191#f0010).

Licença

A licença na fonte original dos dados é dita como “Creative Commons Attribution 4.0 International”.

Dicionário dos dados

Aqui está um dicionário dos dados dentro do dataset. A esquerda temos o termo apresentado na coluna e a direita o seu significado.

hotel -> Tipo de hotel
is_canceled -> Se cancelou ou não
lead_time -> Dias entre a reserva feita e a chegada no hotel
arrival_date_year -> Ano de chegada

arrival_date_month -> Mês de chegada
arrival_date_week_number -> Dia da semana da chegada
arrival_date_day_of_month -> Dia do mês da chegada
stays_in_weekend_nights -> Número de noites de fim de semana
stays_in_week_nights -> Número de noites da semana
adults -> Número de adultos
children -> Número de crianças
babies -> Número de bebês
meal -> Refeição feita
country -> País de origem do hóspede
market_segment -> Segmento de mercado da reserva
distribution_channel -> Canal utilizado para fazer a reserva
previous_cancellations -> Cancelamentos prévios do hóspede
previous_bookings_not_canceled ->Reservas anteriores que não foram canceladas
reserved_room_type ->Tipo de quarto reservado
assigned_room_type ->Tipo de quarto que o hóspede ficou
booking_changes -> Quantidade de mudanças de reserva
deposit_type -> Tipo de pagamento antecipado
agent -> O responsável pela reserva
company -> Empresa associada a reserva
days_in_waiting_list ->Dias que a reserva permaneceu na espera
customer_type ->Tipo de cliente
adr ->Average Daily Rate (Tarifa média diária)
required_car_parking_spaces -> Quantidade de vagas de estacionamento requisitadas
total_of_special_requests -> Quantidade de solicitações especiais
reservation_status -> Situação final da reserva
reservation_status_date -> Data de alteração da situação final da reserva

Unidade de observação

Cada linha do dataset representa em específico uma reserva. Isso demonstra que os 119.390 linhas são referentes à soma das 40.060 reservas do hotel resort e das 79.330 reservas do hotel urbano.

3- Entendimento

Tamanho

O nosso arquivo tem 119.390 registros(40.060 reservas do hotel resort e 79.330 reservas do hotel urbano), com 32 colunas e as chegadas nos hoteis datam do dia 01 de julho de 2015 e vão até 31 de agosto de 2017.

Tipos de variáveis

O dataset tem três tipos de variáveis distintas:

Variáveis numéricas, valores que transitam entre diversos números distintos. As colunas que são preenchidas com variáveis numéricas são:

lead_time;arival_date_year;arival_date_week_number
arival_date_day_of_month;stays_in_weekend_nights
;stay_in_week_nights;Adults;children;babies;previous_cancellations;previous_bo
okings_not_canceled;booking_changes;agent;company;days_in_waiting_list;adr;
total_of_special_requests;reservation_status_date;

Variáveis binárias, valores que transitam entre 0 e 1. As colunas que são preenchidas com variáveis binárias são:

is_canceled;is_repeated_guest;required_car_parking_spaces

Variáveis alfabéticas, valores que são letras e/ou palavras. As colunas que são preenchidas com variáveis alfabéticas são:

hotel,;arrival_date_month;meal;country;market_segment;distribution_channel;res
erved_room_type;assigned_room_type;deposit_type;customer_type;reservation_
status

Colunas com valores faltantes

Existem colunas com valores faltantes no dataset, representados pela string “NULL”, as colunas que têm valores faltantes são:

children, que tem 4 linhas faltantes, que representam 0.00336% de valores faltantes na coluna.

agent, que tem 16.340 linhas faltantes, que representam 13,69% de valores faltantes na coluna.

company, que tem 112.420 linhas faltantes, que representam 94,23% de valores faltantes na coluna.

country, que tem 488 linhas faltantes, que representam 0.409% de valores faltantes na coluna.

Quantidade de categorias

Nas linhas do dataset, é possível visualizar algumas categorias de informações preenchidas, essas categorias são:

-2 tipos de hotel (City Hotel e Resort Hotel)

-12 meses (January, February, March, April, May, June, July, August, September, October, November, December)

-5 tipos de refeição (BB, FB, HB, SC, Undefined)

-177 códigos geográficos (países, territórios e outras regiões) na variável country (PRT, GBR, USA, ESP, IRL, FRA, ROU, NOR, OMN, ARG, POL, DEU, BEL, CHE, CN, GRC, ITA, NLD, DNK, RUS, SWE, AUS, EST, CZE, BRA, FIN, MOZ, BWA, LUX, SVN, ALB, IND, CHN, MEX, MAR, UKR, SMR, LVA, PRI, SRB, CHL, AUT, BLR, LTU, TUR, ZAF, AGO, ISR, CYM, ZMB, CPV, ZWE, DZA, KOR, CRI, HUN, ARE, TUN, JAM, HRV, HKG, IRN, GEO, AND, GIB, URY, JEY, CAF, CYP, COL, GGY, KWT, NGA, MDV, VEN, SVK, FJI, KAZ, PAK, IDN, LBN, PHL, SEN, SYC, AZE, BHR, NZL, THA, DOM, MKD, MYS, ARM, JPN, LKA, CUB, CMR, BIH, MUS, COM, SUR, UGA, BGR, CIV, JOR, SYR, SGP, BDI, SAU, VNM, PLW, QAT, EGY, PER, MLT, MWI, ECU, MDG, ISL, UZB, NPL, BHS, MAC, TGO, STP, KNA, ETH, IRQ, HND, RWA, KHM, MCO, BGD, IMN, TJK, NIC, BEN, VGB, TZA, GAB, GHA, TMP, GLP, KEN, LIE, GNB, MNE, UMI, MYT, FRO, MMR, PAN, BFA, LBY, MLI, NAM, BOL, PRY, BRB, ABW, AIA, SLV, DMA, PYF, GTM, ASM, MRT, NCL, KIR, SDN, ATF, SLE, LAO)

-8 segmentos de mercado (Aviation, Complementary, Corporate, Direct, Groups, Offline TA/TO, Online TA, Undefined)

-5 canais de distribuição (Corporate, Direct, GDS, TA/TO, Undefined)

Problemas encontrados

Ao analisar o dataset, podemos perceber algumas questões que dificultam o entendimento e tratamento dos dados.

O primeiro deles é a ausência de informações nas colunas company, agent, country e children. Principalmente a coluna company que tem mais de 90% dos seus campos faltantes, o que é uma grande porcentagem, coisa que dificulta a análise envolvendo essa coluna do dataset.

O segundo são as variáveis codificadas. Tanto os tipos de quarto (A,B,C) quanto os códigos geográficos (ABW, NIC, LAO) são informações que necessitam de consulta externa para o melhor entendimento.

O terceiro são as variáveis destoantes. A coluna children tem como valores (0,1,2,3,10, NA) e a coluna babies tem como valores (0,1,2,9,10). Essa guinada de valores, do 3 pro 10, do 2 pro 10, dificulta a aferição de informações que não se encaixam nesses números. Um casal com 4,5,6 filhos tem qual valor inserido na tabela? 3 ou 10? 2 ou 10? Isso dificulta na certeza das informações.

4.Preparação

Ao analisar o dataset, foi perceptível a presença de tabelas com colunas vazias:

```
In [15]: df.isna().sum().sort_values(ascending=False)

Out[15]: company                         112593
         agent                           16340
         country                           488
         children                            4
         reserved_room_type                  0
         assigned_room_type                  0
         booking_changes                     0
         deposit_type                        0
         hotel                               0
         previous_cancellations              0
         days_in_waiting_list                0
         customer_type                       0
         adr                                 0
         required_car_parking_spaces         0
         total_of_special_requests           0
         reservation_status                  0
         previous_bookings_not_canceled      0
         is_repeated_guest                   0
         is_canceled                         0
         distribution_channel                0
         market_segment                      0
         meal                                0
         babies                              0
         adults                              0
         stays_in_week_nights                0
         stays_in_weekend_nights             0
         arrival_date_day_of_month           0
         arrival_date_week_number            0
         arrival_date_month                  0
         arrival_date_year                   0
         lead_time                           0
         reservation_status_date             0
         dtype: int64
```

Utilizando o código “df.isna().sum().sort_values(ascending=False)” foi possível puxar as colunas com valores vazios, em ordem crescente. E com o comando “(df.isna().mean()*100).sort_values(ascending=False)” conseguimos retirar as porcentagem de incompletude das tabelas:

```
In [16]: (df.isna().mean() * 100).sort_values(ascending=False)

Out[16]: company                         94.306893
         agent                           13.686238
         country                          0.408744
         children                         0.003350
         reserved_room_type               0.000000
         assigned_room_type               0.000000
         booking_changes                  0.000000
         deposit_type                     0.000000
         hotel                            0.000000
         previous_cancellations           0.000000
         days_in_waiting_list             0.000000
         customer_type                    0.000000
         adr                              0.000000
         required_car_parking_spaces      0.000000
         total_of_special_requests        0.000000
         reservation_status               0.000000
         previous_bookings_not_canceled   0.000000
         is_repeated_guest                0.000000
         is_canceled                      0.000000
         distribution_channel             0.000000
         market_segment                   0.000000
         meal                             0.000000
         babies                           0.000000
         adults                           0.000000
         stays_in_week_nights             0.000000
         stays_in_weekend_nights          0.000000
         arrival_date_day_of_month        0.000000
         arrival_date_week_number         0.000000
         arrival_date_month               0.000000
         arrival_date_year                0.000000
         lead_time                        0.000000
         reservation_status_date          0.000000
         dtype: float64
```

Aqui é mais perceptível o quanto as colunas estão incompletas. Se comparadas com a quantidade total de linhas (119.390) , porcentagens de 94% são extremamente agravantes, porcentagens de 13% são suficientemente relevantes e porcentagens de 0,4% ou menos são quase insignificantes.

Em cima dessas informações, decidimos tratar essas porcentagens mais significativas, para melhorar as análises futuras. Quanto às porcentagens menores, a decisão foi simplesmente ignorar os valores nulos dessas colunas na análise.

Children column

A coluna “children” trata da quantidade de crianças hospedadas. Se pudéssemos ponderar questões sobre essa coluna, teríamos alguns pontos chave de análise:

1. Grau mínimo de colunas vazias (0,003%).
2. Importância para a análise de negócio (pequena para média).

A coluna “children” é importante para a análise. Hóspedes podem cancelar estadias por conta dos filhos, então sim, ela é importante, mas não é tão vital para a análise quanto outras colunas.

Outro argumento importante é a quantia de linhas vazias, ela é tão pequena a ponto não ser capaz de destoar resultados finais, se esses valores não forem contabilizados.

Country column

A coluna “country” traz a informação de qual é o país de origem do hóspede. A porcentagem de colunas vazias corresponde a 0,4%. A porcentagem é relativamente pequena, o que abre um precedente para que essa informação seja ignorada. Porém, o país de origem de um hóspede é uma informação muito importante para a análise.

Distância, desenvolvimento do país, clima, infraestrutura, cultura, existem diversos pontos que podem fazer uma pessoa não se hospedar (seja por uma falta de valorização da própria moeda, seja pela distância de viagem, seja pela diferença climática, pela falta de estrutura para viagens aéreas, pela não adaptabilidade a cultura local, entre outros).

Esses fatores fazem uma diferença significativa na análise de negócio, por isso a decisão tomada é completar essas colunas vazias da seguinte maneira. Será coletado a quantia da aparição dos códigos geográficos nas linhas da tabela, feita uma porcentagem em cima dessas quantidades, e essa porcentagem será usada para preencher as colunas vazias.

Por mais que exista uma chance de a porcentagem colocada não ser a exata informação das colunas vazias, ainda sim, por conta da baixa porcentagem, a diferença para a análise final é mínima.

Mediante o seguinte código”df["country"].value_counts(dropna=False)”, retiramos as quantidades que cada código geográfico aparece nas linhas:

```
In [13]: df["country"].value_counts(dropna=False)

Out[13]: country
         PRT    48590
         GBR    12129
         FRA    10415
         ESP     8568
         DEU     7287
                ...
         NCL        1
         KIR        1
         SDN        1
         ATF        1
         SLE        1
         Name: count, Length: 178, dtype: int64
```

E o código “df["country"].value_counts(normalize=True, dropna=False).mul(100).round(2)” transforma esse valor em uma porcentagem:

```
In [11]: df["country"].value_counts(normalize=True, dropna=False).mul(100).round(2)

Out[11]: country
         PRT    40.70
         GBR    10.16
         FRA     8.72
         ESP     7.18
         DEU     6.10
                ...
         NCL     0.00
         KIR     0.00
         SDN     0.00
         ATF     0.00
         SLE     0.00
         Name: proportion, Length: 178, dtype: float64
```

Como é possível visualizar, o código “PRT” (que se refere a Portugal) preenche 40% das nossas linhas da coluna “country”. Por isso decidimos preencher as colunas faltantes com o código “PRT”.

Agent column

A coluna “agent” representa o funcionário que fez a reserva do hóspede. A porcentagem de colunas vazias corresponde a 13%. A porcentagem é significante, e a informação de quem fez a reserva de um hóspede abre precedentes para análises mais profundas que vão além das nossas perguntas principais (análise de desempenho de funcionário, relação entre abordagem funcionário-cliente, metas mensais, entre outros).

Por esses motivos, é necessário completar as linhas faltantes. Para fazermos isso, nós precisamos coletar a média de aparições do número de um agente nas linhas da tabela, utilizando-se assim desse valor para preencher as colunas vazias.

Mediante o seguinte código ”df["agent"].value_counts(dropna=False).head(10) ”, retiramos as quantidades que cada código de agente que aparece nas linhas:

```
Out[ ]: agent
        9.0      31961
        NaN      16340
        240.0    13922
        1.0       7191
        14.0      3640
        7.0       3539
        6.0       3290
        250.0     2870
        241.0     1721
        28.0      1666
        Name: count, dtype: int64
```

E o código “df['agent'].value_counts(normalize=True, dropna=False).mul(100).round(2)” transforma esse valor em uma porcentagem:

```
Out[13]: agent
         9.0      26.77
         NaN      13.69
         240.0    11.66
         1.0       6.02
         14.0      3.05
                  ...
         444.0     0.00
         408.0     0.00
         388.0     0.00
         453.0     0.00
         480.0     0.00
         Name: proportion, Length: 334, dtype: float64
```

Como é possível visualizar, o código “9” preenche 26% da coluna. Logo, nós vamos preencher as linhas vazias com o código 9.

Company column

A coluna “company” traz a informação de qual é a empresa associada à reserva. A porcentagem de colunas vazias corresponde a 94% e isso é um grande problema. Nós não temos como saber o porquê dessa falta gigantesca de informações na coluna “company”. Em cima disso podemos apenas criar suposições.

As informações associadas às reservas sempre devem ser preenchidas corretamente e em sua total completude para que as análises de negócio sejam o mais precisas possível. Situações de 0% a 5% de incompletude são relativamente comuns, 6% a 10% são relativamente ruins mas, podem ser relevadas. 11% a 20% são péssimas e devem ser tratadas. Mais de 20% demonstra um descaso com as informações e uma situação agravante para as análises.

Agora, imaginemos, o que fez a pessoa (ou pessoas) que completaram essa tabela deixar 94% dessa coluna vazia? É uma porcentagem faltante absurda, que na nossa análise gerou provém de dois motivos:

Motivo 1: As pessoas envolvidas não achavam relevante ir atrás desses dados.

Motivo 2: Esses dados não existiam na maioria dos casos registrados no dataset.

Seja qual for o motivo, fica claro que essas informações não pareciam ser importantes na hora de serem registradas. E isso abre um precedente para nós ignorarmos essas informações e apenas, descartá-las da nossa análise.

Por mais que possam sim, ter análises referentes a esses dados e, por consequência, necessitar dessas informações em casos específicos, a nossa coluna “company” tem mais do que ¾ de informações incompletas. Essa massiva quantidade de informações dificulta até aos métodos de preenchimento. Se mais de 75% da coluna está incompleta, como podemos preencher essa tabela? Média, moda e mediana estão fora de questão, pois não existem dados o suficiente para tirar essas conclusões.

Preencher com o que achamos que é? Pouco efetivo e permite uma manipulação gigantesca dos resultados, já que o que está sendo preenchido parte apenas de um achismo. O que escolhemos fazer é simplesmente ignorar esses dados em nossa análise e retificar isso posteriormente.

5.Exploração

6. Modelagem

7. Conclusão e limitações