Devoluções, Descontos e Estoque: uma Análise Exploratória de Dados de Vendas em uma Boutique de Moda

Naiane Teixeira

Programação para Ciência de Dados – Prof. Gustavo Teixeira

Resumo. O varejo de moda convive com três custos difíceis de evitar: a devolução de produtos, o desconto (markdown) usado para escoar coleções e o estoque parado. Este trabalho utiliza um conjunto de dados público de uma boutique de moda, com 2.176 produtos e 14 variáveis, para investigar três perguntas: (i) quais características do produto mais se associam à devolução; (ii) se o desconto aplicado reflete uma característica real do produto ou um erro de precificação inicial; e (iii) quais categorias concentram maior necessidade de desconto e, portanto, giro de estoque mais lento. Esta primeira etapa apresenta a introdução, a origem e a estrutura dos dados, o entendimento detalhado de cada variável e as decisões de preparação necessárias para responder às perguntas nas etapas seguintes.

Palavras-chave: ciência de dados; varejo de moda; devolução de produtos; precificação; análise exploratória.

Abstract. Fashion retail deals with three hard-to-avoid costs: product returns, markdowns used to clear collections, and slow-moving stock. This work uses a public dataset from a fashion boutique, with 2,176 products and 14 variables, to investigate three questions: (i) which product characteristics are most associated with returns; (ii) whether the discount applied reflects a real product trait or an initial pricing error; and (iii) which categories concentrate the greatest need for discounting and, therefore, slower stock turnover. This first stage presents the introduction, the data source and structure, a detailed understanding of each variable, and the preparation decisions required to answer the questions in the following stage.

Keywords: data science; fashion retail; product returns; pricing; exploratory analysis.

1. Introdução

A precificação no varejo de moda raramente é definida uma única vez. Uma peça entra em coleção com um preço original e, ao longo da estação, pode receber desconto (markdown) para acelerar a venda; ainda assim, uma fração dos produtos vendidos volta para a loja como devolução. Cada uma dessas três situações — desconto, devolução e estoque parado — tem um custo direto, mas nem sempre é óbvio se elas estão relacionadas às mesmas causas: um produto é devolvido porque o tamanho não serve, porque a cor destoa da foto, porque o cliente mudou de ideia, ou porque a peça tinha um defeito real?

Este trabalho usa um conjunto de dados de vendas de uma boutique de moda para investigar três perguntas de negócio:

P1. Quais características do produto (categoria, marca, estação, cor, tamanho, preço, percentual de desconto) mais se associam à probabilidade de devolução — a ponto de servirem de sinal de risco antes mesmo da venda?

P2. O desconto aplicado varia de forma consistente entre categorias, ou está distribuído de forma aleatória? Em outras palavras, o markdown reflete uma decisão comercial por categoria, ou um ajuste caso a caso?

P3. Quais categorias concentram, ao mesmo tempo, o maior desconto médio e a maior taxa de devolução — e deveriam, por isso, ser repensadas na próxima estação de compras?

A pergunta P1 tem como alvo natural a variável *is_returned* (devolvido ou não), o que a torna também a base para a modelagem preditiva prevista na Etapa 2 deste trabalho. Este documento corresponde à Etapa 1: apresenta a origem dos dados, o entendimento de cada variável e as decisões de preparação necessárias antes de qualquer resposta às perguntas acima, que serão exploradas na Etapa 2.

Por que estas três perguntas

As três perguntas têm sujeito e recorte definidos, e nenhuma se resolve com uma média simples ou descreve o uso de um modelo como fim em si. P1 recorta um conjunto específico de características do produto e aponta para uma ação concreta: sinalizar risco de devolução antes da venda. P2 recorta a comparação entre categorias e aponta para uma decisão sobre a política de desconto. P3 combina duas métricas (desconto médio e taxa de devolução) para apontar quais categorias merecem revisão na próxima compra. Em nenhum dos três casos a resposta é apenas "interessante": cada uma muda o que a boutique faria a seguir — o que revisar, o que descontar, o que comprar menos.

2. Os dados

Fonte. Retail Fashion Boutique Data – Sales Analytics 2025, publicado no Kaggle pelo usuário pratyushpuri, disponível em https://www.kaggle.com/datasets/pratyushpuri/retail-fashion-boutique-data-sales-analytics-2025.

Licença. Apache License 2.0, conforme declarado na página do conjunto de dados no Kaggle — permite uso, modificação e redistribuição, inclusive para fins acadêmicos, desde que mantida a atribuição à fonte original.

Unidade de observação. Cada linha corresponde a um produto individual vendido pela boutique (identificado por *product_id*), e não a uma transação de cliente nem a um dia de vendas.

Dimensão. 2.176 linhas e 14 colunas, sem linhas nem identificadores duplicados.

O dicionário de dados, com o tipo, o percentual de nulos e o número de valores distintos de cada variável, está na Tabela 1.

3. Entendimento

A Tabela 1 resume as 14 variáveis do conjunto de dados.

Tabela 1. Dicionário de dados e completude por variável.

Variável	Tipo	% nulos	Distintos
product_id	texto (id)	0,0	2176
category	categórica	0,0	6
brand	categórica	0,0	8
season	categórica	0,0	4
size	categórica	22,6	6
color	categórica	0,0	11
original_price	numérica cont.	0,0	2061
markdown_percentage	numérica cont.	0,0	458
current_price	numérica cont.	0,0	2025
purchase_date	temporal	0,0	273
stock_quantity	numérica disc.	0,0	51
customer_rating	numérica cont.	16,6	41
is_returned	booleana	0,0	2
return_reason	categórica	85,3	6

Tipos e granularidade

Das 14 variáveis, 4 são numéricas contínuas (*original_price*, *markdown_percentage*, *current_price*, *customer_rating*), 1 é numérica discreta (*stock_quantity*), 5 são categóricas nominais (*category*, *brand*, *season*, *size*, *color*), 1 é temporal (*purchase_date*) e 1 é booleana (*is_returned*). A variável *return_reason* é categórica, mas de natureza condicional — só existe quando *is_returned* é verdadeiro.

category, *brand* e *color* cumprem a exigência de cardinalidade acima de 5 valores distintos (6, 8 e 11, respectivamente), o que os torna adequados tanto para agrupamento quanto, mais adiante, para codificação em um modelo preditivo.

purchase_date cobre 273 datas distintas entre 06/08/2024 e 06/08/2025 — treze meses corridos, o suficiente para observar variação sazonal completa.

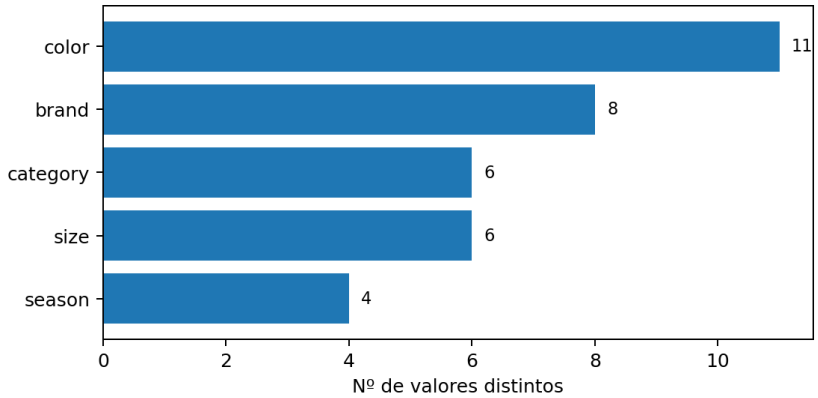


Figura 1. Número de valores distintos por variável categórica.

A sujeira encontrada

Duas colunas têm ausência de dados dentro de uma faixa que exige decisão, não descarte automático: *size* (22,6% nula) e *customer_rating* (16,6% nula). Já *return_reason* está 85,3% vazia — mas, ao contrário das duas anteriores, esse vazio não é sujeira: ele é estrutural, porque só um produto devolvido (320 de 2.176, ou 14,7%) tem motivo de devolução para registrar. Confundir os dois tipos de ausência

— dado que falta por falha de coleta e dado que falta porque a pergunta não se aplica — seria o erro mais fácil de cometer nesta base.

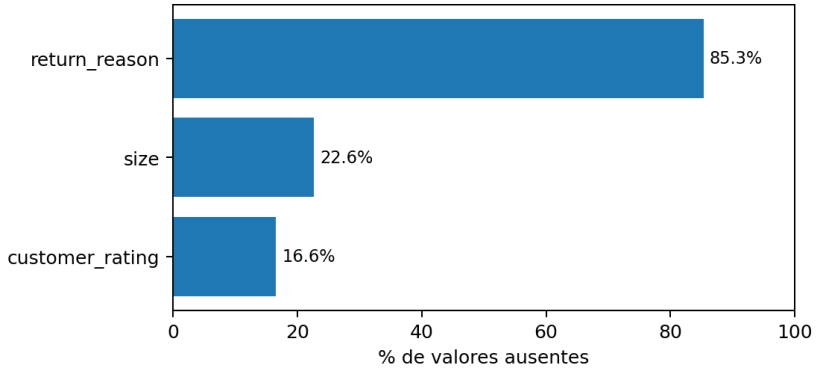


Figura 2. Percentual de valores ausentes nas três variáveis afetadas.

Não foram encontradas inconsistências entre as colunas de preço: em nenhuma das 2.176 linhas o valor de *current_price* diverge do que se obtém aplicando *markdown_percentage* sobre *original_price* (diferença máxima de meio centavo, atribuível a arredondamento). Também não há duplicidade de *product_id* nem valores fora de faixa plausível: preços entre R$ 15,14 e R$ 249,98, avaliações entre 1 e 5, estoque entre 0 e 50 unidades.

Um limite do conjunto de dados

O enunciado pede ao menos uma coluna de texto livre (nome, endereço, descrição). Este conjunto de dados não possui uma coluna dessa natureza: *product_id* é um identificador, não um texto descritivo, e as demais colunas textuais (*category*, *brand*, *season*, *size*, *color*, *return_reason*) são, na prática, categóricas de vocabulário fechado. Essa é uma limitação real da base, registrada aqui em vez de forçada a se encaixar — as demais nove exigências (tamanho, largura, numéricas, categóricas, temporal e sujeira) são cumpridas com folga, conforme detalhado acima.

4. Preparação

A partir do entendimento acima, as seguintes transformações estão planejadas antes da exploração e da modelagem da Etapa 2:

purchase_date → conversão para tipo data e derivação de mês e estação do ano de compra, permitindo cruzar sazonalidade de venda com a coluna *season* (que descreve a coleção, não a data da venda) — as duas informações respondem perguntas diferentes e serão mantidas separadas.

size → os 22,6% ausentes serão mantidos como categoria explícita (“não informado”), em vez de imputados por moda, já que o tamanho é justamente uma das hipóteses de causa de devolução (P1): apagar essa ausência esconderia informação relevante para a própria pergunta.

customer_rating → os 16,6% ausentes serão tratados como “sem avaliação” e não como nota zero, para não distorcer a média; a decisão entre imputação e exclusão será revisitada na Etapa 2, conforme a técnica de modelagem escolhida.

return_reason → os 85,3% vazios serão recodificados para a categoria “não devolvido”, eliminando a ambiguidade entre “faltou registrar” e “não se aplica”.

markdown_flag (nova coluna derivada) → variável booleana indicando se o produto recebeu algum desconto (878 de 2.176 produtos, 40,3%), útil para separar “quanto” desconto de “se houve” desconto na análise da pergunta P2.

Nenhuma linha será removida nesta etapa: não há duplicidade, e os valores ausentes identificados têm significado próprio, não indicam erro de coleta que justifique exclusão.

Referências

[1] KAGGLE. *Retail Fashion Boutique Data – Sales Analytics 2025*. Licença: Apache License 2.0. Disponível em: https://www.kaggle.com/datasets/pratyushpuri/retail-fashion-boutique-data-sales-analytics-2025. Acesso em: set. 2026.

[2] PROVOST, F.; FAWCETT, T. *Data Science for Business*. Sebastopol: O'Reilly Media, 2013.

[3] MCKINNEY, W. *Python for Data Analysis*. 3. ed. Sebastopol: O'Reilly Media, 2022.